


Ames, Iowa : Alternative to the Boston Housing Data

as an End of Semester Regression Project

การประยุกต์ Multiple Linear Regression และ Ridge Regression



บทนำ

การวิเคราะห์ราคาบ้านนิยมใช้ Multiple Linear Regression เพราะช่วยอธิบายความสัมพันธ์ระหว่างราคาบ้านกับปัจจัยต่าง ๆ ได้ชัดเจน เดิมนิยมใช้ Boston Housing Data Set แต่ข้อมูลมีขนาดเล็กและล้าสมัย จึงเปลี่ยนมาใช้ Ames Housing Data Set (De Cock, 2011) ที่มีข้อมูลมากและสมเหมาะกว่า อย่างไรก็ตาม ข้อมูลที่มีตัวแปรจำนวนมากทำให้เกิดปัญหาความสัมพันธ์กันสูง (multicollinearity) งานนี้จึงใช้ Multiple Linear Regression ใช้ Ordinary Least Squares (OLS) เป็นโมเดลพื้นฐาน และเปรียบเทียบกับ Ridge Regression ที่ใช้ Regularization techniques เพื่อเพิ่มเสถียรภาพของโมเดล โดยประเมินผลด้วยวิธีการตรวจสอบความถูกต้อง (RMSE, MAE, R^2)



วัตถุประสงค์หลักของงาน



- เพื่อศึกษาการใช้ Multiple Linear Regression กับข้อมูลราคาบ้านที่มีตัวแปรจำนวนมาก
- เพื่อแสดงข้อจำกัดของ Ordinary Least Squares (OLS) เมื่อข้อมูลมีปัญหาตัวแปรอิสระที่มีความสัมพันธ์กันสูง (multicollinearity)
- เพื่อสาธิตการใช้ Ridge Regression เป็นแนวทางแก้ไขปัญหาสัมประสิทธิ์ไม่เสถียร
- เพื่อเปรียบเทียบประสิทธิภาพของโมเดลโดยใช้ตัวชี้วัดมาตรฐาน (RMSE, MAE, R^2)
- เพื่อใช้เป็น case study ทางการศึกษาแทน Boston Housing Data

“งานศึกษานี้มุ่งเน้นการทำความเข้าใจแนวคิดของแบบจำลองถดถอย
เชิงเส้น ความเสถียรของค่าสัมประสิทธิ์ และการประยุกต์ใช้
regularization techniques”




เปเปอร์หลัก (De Cock, 2011) ทำอะไร?

เปเปอร์หลัก:

Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project

แนวคิดหลัก:

- เสนอ Ames Housing Data เป็น dataset เพื่อการเรียนรู้การสอนแทน Boston
- เน้นการสาธิตแนวคิด Multiple Linear Regression ในบริบทของข้อมูลจริง
- มุ่งเน้นอธิบายความสัมพันธ์ของตัวแปร
- เหตุผลที่ไม่ใช้ Boston:
 - ข้อมูลเก่า (Boston ใช้ข้อมูลช่วงปี 1970s)
 - ตัวแปรน้อย
 - ไม่เหมาะกับข้อมูลมิติสูง
- เปลี่ยนใช้ Ames Housing แทน:
 - ข้อมูลจากธุรกรรมจริง
 - ตัวแปรเยอะ
 - เหมาะสำหรับสอน regression ขั้นสูง



เปเปอร์นี้เพิ่มอะไร?

สิ่งที่เพิ่มเข้าไป:

- ใช้กรอบแนวคิดเดียวกับ De Cock (2011)
 - สร้าง baseline model (OLS) อย่างเป็นระบบ
 - เพิ่ม Ridge Regression + 10-fold Cross-Validation
 - ใช้ train-test split (70/30) เพื่อประเมินโมเดล
- รายงานตัวชี้วัดเชิงตัวเลข:
 - RMSE (Root Mean Squared Error)
 - MAE (Mean Absolute Error)
 - R^2 (R-Squared)
- แสดงกราฟ:
 - Cross-validation curve
 - Predicted vs Actual



แหล่งข้อมูล

ชุดข้อมูลที่ใช้

- Ames Housing Data Set
- ข้อมูลราคาบ้านจริงในเมือง Ames, Iowa
- ประกอบด้วย:
 - ตัวแปรเชิงปริมาณ (พื้นที่, ปีที่สร้าง, จำนวนโรงรถ ฯลฯ)
 - ตัวแปรเชิงหมวดหมู่ (ย่านที่อยู่อาศัย, การแบ่งเขตพื้นที่)

เหตุผลที่เลือกชุดข้อมูลนี้ :

- ข้อมูลเริ่มตั้งแต่ ปี ค.ศ. 2006 – 2010
- ตัวแปร 82 ตัว
- ข้อมูล 2,930 แถว
- เหมาะกับการศึกษาปัญหา ตัวแปรสัมพันธ์กันสูง

การเตรียมข้อมูล

ขั้นตอนการเตรียมข้อมูล

- 1.ลบตัวแปรบ้างตัวที่ไม่จำเป็น
- 2.จัดการ missing values
 - ตัวแปรเชิงตัวอักษร → แทนด้วย None
 - ตัวแปรเชิงตัวเลข → แทนด้วย median
- 3.แปลงตัวแปรเชิงหมวดหมู่
- 4.กำหนดตัวแปรเป้าหมาย: “price”

เหตุผล :

- ลด bias จาก outliers
- รองรับ regression ที่ต้องใช้ตัวเลข



โมเดลที่ใช้

Multiple Linear Regression

Ordinary Least Squares (OLS) เป็นวิธีการประมาณค่าสัมประสิทธิ์ของสมการถดถอยเชิงเส้นพหุคูณ โดยมีวัตถุประสงค์เพื่อหาค่าพารามิเตอร์ที่ทำให้ผลรวมกำลังสองของความคลาดเคลื่อนระหว่างค่าจริงและค่าที่โมเดลทำนายได้มีค่าน้อยที่สุด

สมการ

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \varepsilon_i$$

- y_i = ราคาบ้านหลังที่ i
- β_0 = ค่าคงที่
- β_j = ค่าสัมประสิทธิ์ของตัวแปรอิสระตัวที่ j
- x_{ij} = ค่าของตัวแปรอิสระตัวที่ j สำหรับบ้านหลังที่ i
- ε_i = ค่าความคลาดเคลื่อน
- p = จำนวนตัวแปรอิสระ

OLS ทำการประมาณค่าสัมประสิทธิ์โดยแก้ปัญหาค่าต่ำสุดของฟังก์ชันสูญเสีย

ปัญหาของ OLS ในข้อมูลมิติสูง

- ตัวแปรจำนวนมาก → ตัวแปรสัมพันธ์กันสูง
- ผลกระทบ:
 - ค่าสัมประสิทธิ์จะไม่เสถียร, ความแม่นยำในการทำนายลดลง, overfitting ได้ง่าย

Ridge Regression

Regularization techniques เป็นการขยายแนวคิดของ OLS โดยการเพิ่ม penalty term เข้าไปในฟังก์ชันสูญเสีย เพื่อควบคุมขนาดของค่าสัมประสิทธิ์ และลดปัญหาที่เกิดจากตัวแปรสัมพันธ์กันสูง

สมการ

$$\min_{\beta} \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$

- $\min_{\beta}$ คือ หาค่าสัมประสิทธิ์ของโมเดลที่ทำให้ฟังก์ชัน loss มีค่าน้อยที่สุด
- y_i = ราคาบ้านหลังที่ i
- $\hat{y}_i$ = ค่าที่โมเดลทำนายได้
- β_j = ค่าสัมประสิทธิ์ของตัวแปรอิสระตัวที่ j
- λ = regularization parameter ใช้ควบคุมความแรงของ penalty
- p = จำนวนตัวแปรอิสระ
- n = จำนวนข้อมูล

หน้าที่

ลดผลกระทบจากตัวแปรสัมพันธ์กันสูง ทำให้ค่าสัมประสิทธิ์ไม่เหวี่ยง หรือผันผวนรุนแรง เพิ่มความเสถียรของโมเดล และเหมาะกับข้อมูลที่มีตัวแปรจำนวนมาก

ข้อดี

- Ridge ไม่ตัดตัวแปรทิ้ง แต่จะลดขนาดค่าสัมประสิทธิ์ให้เหมาะสมคงโครงสร้างโมเดล ไว้ทั้งหมด




การเลือกค่า λ ด้วย Cross-Validation

วิธีเลือก λ

- ใช้ 10-fold Cross-Validation
- แบ่ง training set เป็น 10 ส่วน ใช้ 9 ส่วนฝึก + 1 ส่วนทดสอบ ทำซ้ำจนครบ 10 ครั้ง
- วัดค่า Mean Squared Error (MSE)
 - การเลือกค่า λ ด้วย Cross-Validation ช่วยควบคุมความซับซ้อนของโมเดลและลดความเสี่ยงของ overfitting ซึ่งเป็นปัญหาที่พบบ่อยใน regression ที่มีตัวแปรจำนวนมาก

ค่าที่พิจารณา:

- $\lambda_{\min}$ → MSE ต่ำสุด ใช้เมื่อเน้นความถูกต้อง
- λ_{1se} → โมเดลเรียบง่ายกว่าแต่เสถียร



ข้อมูลที่ได้จากกราฟ

พบว่า Cross-validation curve แสดงความสัมพันธ์ระหว่าง $\log(\lambda)$ กับ MSE จุดต่ำสุดที่ได้ คือ

- $\log(\lambda_{\min}) = 10.81$
- $\log(\lambda_{1se}) = 12.02$



ตารางผลลัพธ์

ตัวชี้วัด	De Cock (2011)	Multiple Linear Regression (OLS)	Ridge Regression
R ²	0.71	0.83	0.87
RMSE	ไม่รายงาน	32,160	28,986
MAE	ไม่รายงาน	21,426	17,238
การประเมิน	In-sample	Test set	Test set




ผลการวิเคราะห์

- Ridge ให้ RMSE และ MAE ต่ำกว่า OLS หมายความว่า ความคลาดเคลื่อนเฉลี่ยลดลง
 - Ridge ให้ R² สูงกว่า OLS หมายความว่า อธิบายความแปรปรวนของราคาได้ดีขึ้น
- จึงสรุปว่า Ridge “ดีกว่า OLS” ในแง่ความแม่นยำบนชุดทดสอบ ความเสถียร ภายใต้ข้อมูลที่มีตัวแปรจำนวนมากและสัมพันธ์กันสูง



กราฟ



Predicted vs Actual

- จุดใกล้เส้น $45^\circ \rightarrow$ โมเดล fit ดี
- เป็นการใช้เพื่อประเมินความสอดคล้องเชิงโครงสร้างของโมเดลไม่ได้ใช้เพื่อการพยากรณ์ค่าจริงในอนาคต



สรุปผล

งานศึกษานี้มุ่งเน้นการเปรียบเทียบเชิงวิธีการระหว่าง Ordinary Least Squares (OLS) และ regularization techniques ภายใต้ข้อมูลที่มีตัวแปรจำนวนมากและมีความสัมพันธ์กันสูง โดยใช้ Ames Housing Data Set เป็นกรณีศึกษา OLS ถูกนำมาใช้เป็นแบบจำลองพื้นฐาน เนื่องจากมีโครงสร้างที่เรียบง่ายและเข้าใจได้ง่าย อย่างไรก็ตาม วิธีการดังกล่าวมีข้อจำกัดด้านความเสถียรของค่าสัมประสิทธิ์เมื่อเผชิญกับปัญหาตัวแปรสัมพันธ์กันสูง (multicollinearity)

ดังนั้น การประยุกต์ใช้ Ridge Regression ร่วมกับ Cross-Validation ช่วยลดความแปรปรวนของค่าสัมประสิทธิ์ และเพิ่มความเสถียรของโมเดลได้อย่างชัดเจนขึ้น และผลการศึกษานี้ชี้ให้เห็นว่า Ames Housing Data Set มีความเหมาะสมในการใช้เป็นกรณีศึกษาแทน Boston Housing Data สำหรับการเรียนการสอน regression ขั้นสูง

ข้อเสนอแนะเพิ่มเติม

ในงานวิจัยต่อไป อาจพิจารณาศึกษาการประยุกต์ใช้ Lasso Regression เพื่อเปรียบเทียบผลของการใช้ตัวแปรทั้งหมดกับการคัดเลือกตัวแปรบางส่วนออกไป และประเมินผลกระทบต่อความเรียบง่ายและความเสถียรของโมเดล





Thank You

