รายงาน

ข้อมูลราคาทองคำรายวัน

เสนอ

อาจารย์ พรรณนิภา รินทระ

จัดทำโดย

นางสาวชุติมน นันทะเสนา

รหัส 6640201080

รายงานนี้เป็นส่วนหนึ่งของวิชา การพยากรณ์สำหรับวิทยาการข้อมูล รหัสวิชา 04256221

ภาคเรียนที่ 2 ปีการศึกษา 2568

มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตเฉลิมพระเกียรติ จังหวัดสกลนคร

Contents **page**

1. Data Presentation	**3**
1.1. Correlation Structure	**4**
1.2. การทำ Differencing	**5**
2. Model Identification	**7**
2.1. วิเคราะห์จาก ACF และ PACF	**7-9**
2.2. วิเคราะห์จากการใช้เกณฑ์ Information Criteria (IC)	**7-9**
3. Model Diagnostic	**10**
3.1. ตรวจสอบความเหมาะสมของตัวแบบ	**10**
3.2. เปรียบเทียบความคลาดเคลื่อนของการพยากรณ์จากตัวแบบที่ได้	**11**
4. Forecasting	**11**
4.1. พยากรณ์ราคาทองของวันที่ 11 - 20 เมษายน 2024	**11**
4.2. การพยากรณ์ช่วงวันที่ 21–30 เมษายน 2024	**12**
4.3. กราฟการพยากรณ์ช่วงวันที่ 11–30 เมษายน 2024	**12-13**

1. Data Presentation

ข้อมูลที่ใช้ในงานวิจัยนี้เป็นข้อมูลราคาทองคำรายวัน ตั้งแต่วันที่ 2 มกราคม 2023 ถึง 20 เมษายน 2024 โดยหน่วยเป็น $ / kg ซึ่งได้มาจากไฟล์ '4. gold.xlsx'

คอลัมน์ที่สำคัญ ได้แก่:

- วันที่ (date)
- ราคาทองคำ (price)

เพื่อพยากรณ์ราคาทองคำรายวัน เราจะฝึกโมเดล ARIMA ที่แตกต่างกันเพื่อระบุโมเดลที่ดีที่สุด โดยใช้เกณฑ์ที่ศึกษา นอกจากนี้ เราจะไม่ใช้การสังเกตจากข้อมูลทั้งหมด แต่จะใช้ข้อมูลถึงวันที่ 10 เมษายน 2024 เท่านั้นสำหรับการฝึกโมเดล

จากการพล็อตอนุกรมเวลา พบว่า ข้อมูลกระจายรอบค่าคงที่ค่าใดค่าหนึ่ง มีแนวโน้มขึ้นอย่างชัดเจน และยังไม่มีรูปแบบที่ชัดเจน

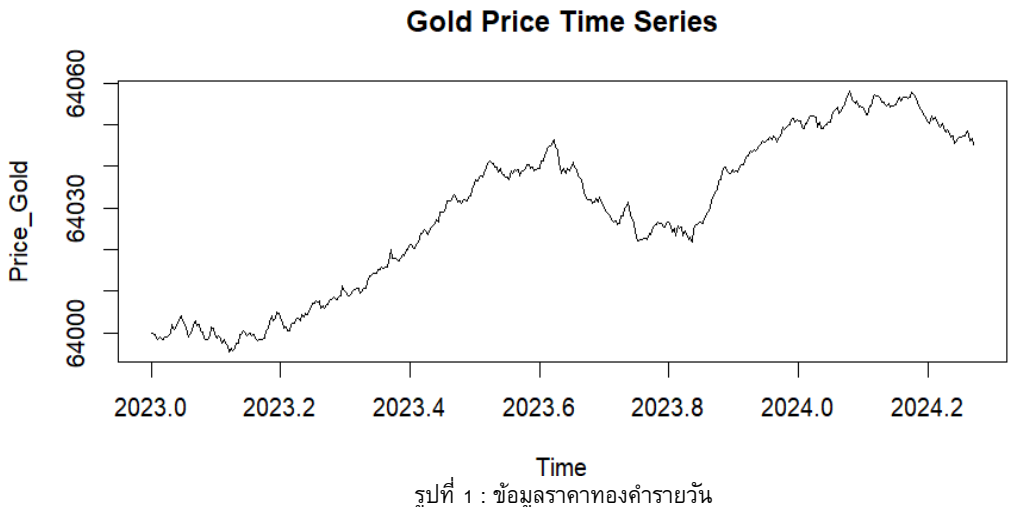

รูปที่ 1 : ข้อมูลราคาทองคำรายวัน

```
library(forecast)
library(urca)
library(readxl)
library(TSA)

# อ่านข้อมูล
X4_gold = read_excel("Forceting Final/งานล่าสุด/4. gold.xlsx",
                     sheet = "gold_model")
#==============================================================================#
# ข้อที่ 1: พล็อตข้อมูล
Price_Gold = ts(X4_gold$price, start = c(2023, 1, 2), frequency = 365)
plot(Price_Gold, main="Gold Price Time Series", ylab="Price_Gold", xlab="Time")
abline(h = mean(Price_Gold), col = "red", lty = 2)
```

1.1. Correlation Structure

ในส่วนนี้จะวิเคราะห์ Autocorrelation Function (ACF) และ Partial Autocorrelation Function (PACF) เพื่อระบุว่าข้อมูลเป็น Stationary หรือไม่

จากการตรวจสอบ ACF และ PACF ของข้อมูลราคาทองคำ โดยสังเกตจากรูปที่ 2 พบว่า ACF ค่อยๆ ลดลงอย่างเอ็กซ์โพเนนเชียล แสดงว่า ข้อมูลมีแนวโน้ม (Trend) และเป็น Non-Stationary และ PACF พบว่า ลดลงเข้าใกล้ 0 อย่างรวดเร็วใน lag แรกๆ ข้อมูลอาจจะเป็น Stationary

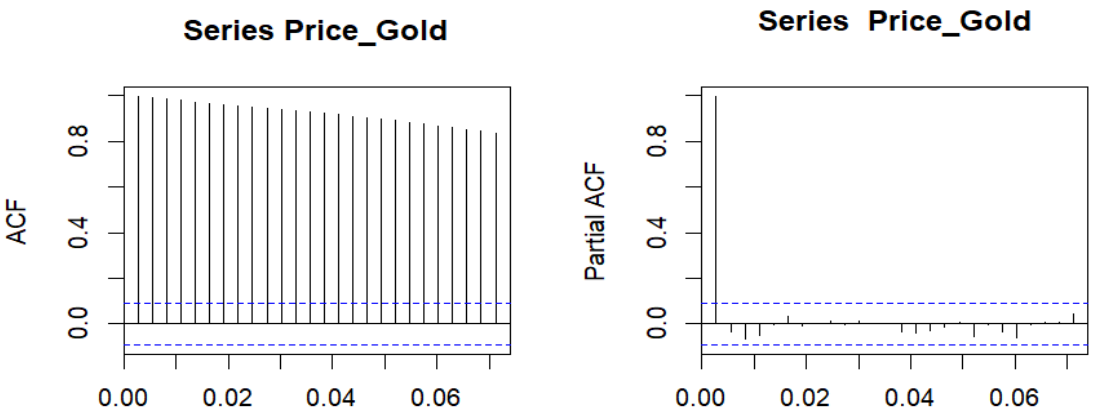

รูปที่ 2 : ACF และ PACF ของราคาทองคำรายวัน (non-stationary)

เนื่องจาก ทำการดูผ่าน ACF และ PACF ไม่ชัดเจนว่าอนุกรมเวลาเป็น Stationary หรือไม่ จึงได้ทำการวิเคราะห์ด้วย Augmented Dickey-Fuller Test (ADF Test) เพื่อเช็คอีกรอบ

สมมติฐาน

H_0 : $\pi = 0$ $\longrightarrow$ อนุกรมเวลาเป็น non- stationary

H_A : $\pi < 0$ $\longrightarrow$ อนุกรมเวลาเป็น stationary

ACF Statistic	p-value	Critical Value	
		1%	5%
10%			
3.13			

ตารางที่ 1 : Dickey-Fuller Test Unit Root Test

ผลการทดสอบ ADF

- ค่า test statistic = - 0.8533 และ critical values = -3.42 (5%)
- ค่า p-value = 0.3724 > α = 0.05

ดังนั้น ค่า test statistic = ค่า critical values จึงยอมรับ H_0 และสรุปได้ว่า อนุกรมเวลาเป็น non- stationary

หลังจากทราบแล้วว่า อนุกรมเวลา เป็น non- stationary ดังนั้นจึงต้องทำการ Differencing เพื่อลบแนวโน้มออก และทำให้ข้อมูลเป็น Stationary

```
# เช็ค ACF และ PACF
par(mfrow = c(1,2))
acf(Price_Gold)
pacf(Price_Gold)

# ตรวจสอบความเป็น Stationary
summary(ur.df(Price_Gold, type = "trend", selectlags = "AIC"))
```

1.2. การทำ Differencing

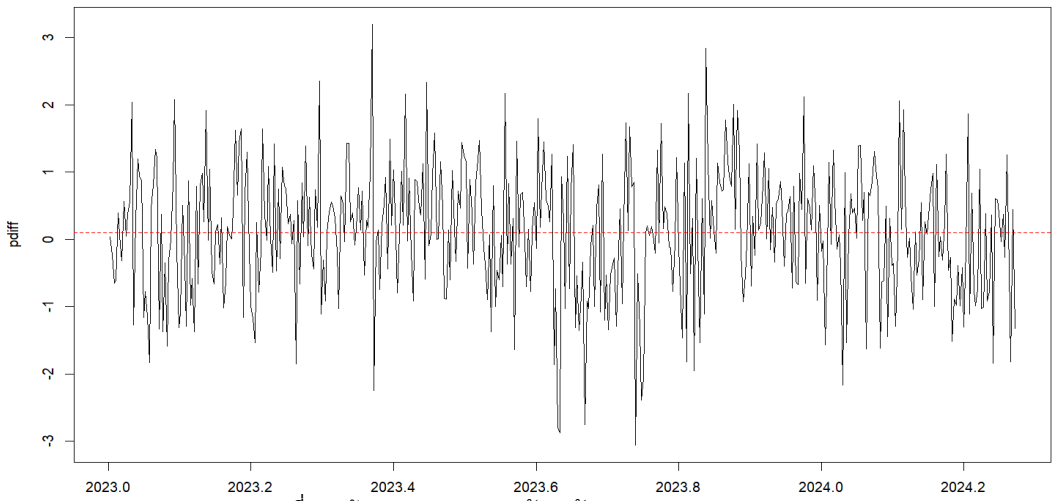

รูปที่ 3 : ข้อมูลราคาองคำรายวัน หลังจากทำ Differencing (d = 1)

หลังจากทำ Differencing (d = 1) แล้ว สังเกตได้ว่าข้อมูลแกว่งอยู่รอบ ๆ ค่าศูนย์และไม่มีแนวโน้มที่ชัดเจน แสดงให้เห็นว่าการเปลี่ยนแปลงของราคาทองคำมีลักษณะเป็น Random Walk

```
# ทำข้อมูลให้เป็น Stationary
pdiff = diff(Price_Gold, lag = 1)
pdiff = ts(pdiff, start = c(2023, 3), frequency = 365)  # ปรับให้ตรงกับข้อมูลที่ต่างกัน

plot(pdiff)
abline(h = mean(pdiff), col = "red", lty = 2)
```

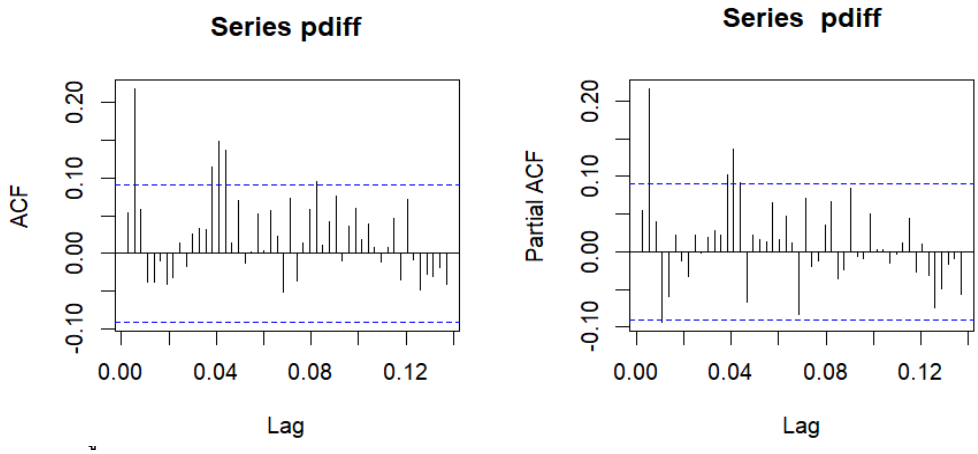

ทำการวิเคราะห์ด้วย Augmented Dickey-Fuller Test (ADF Test) เพื่อเช็คอีกรอบว่าเป็น stationary แล้ว

ACF Statistic	p-value	Critical Value		
		1%	5%	10%
-11.664	2.2e-16	-2.58	-1.95	-
1.62				

ตารางที่ 2 : Dickey-Fuller Test Unit Root Test

ผลการทดสอบ ADF

- ค่า test statistic = -11.664 และ critical values = -1.95 (5%)
- ค่า p-value = 2.2e-16 < α = 0.05

ดังนั้น ค่า test statistic < ค่า critical values จึงยอมรับ $\mathbf{H_A}$ และสรุปได้ว่า อนุกรมเวลาเป็น stationary

```
# เช็ค ACF และ PACF
par(mfrow = c(1,2))
acf(Price_Gold)
pacf(Price_Gold)

# ตรวจสอบความเป็น Stationary
summary(ur.df(Price_Gold, type = "trend", selectlags = "AIC"))
```

2. Model Identification

เพื่อให้ได้โมเดล ARIMA ที่เหมาะสมที่สุด จำเป็นต้องกำหนดค่าพารามิเตอร์ของแบบจำลอง (p, d, q) อย่างเหมาะสม ในการเลือกแบบจำลองที่เหมาะสม จะพิจารณาจากการวิเคราะห์ฟังก์ชัน Autocorrelation Function (ACF) และ Partial Autocorrelation Function (PACF) ควบคู่กับเกณฑ์การเลือกโมเดล เช่น Akaike Information Criterion (AIC) และ Bayesian Information Criterion (BIC) ซึ่งช่วยให้สามารถกำหนดค่าพารามิเตอร์ของโมเดลได้อย่างมีประสิทธิภาพสูงสุด

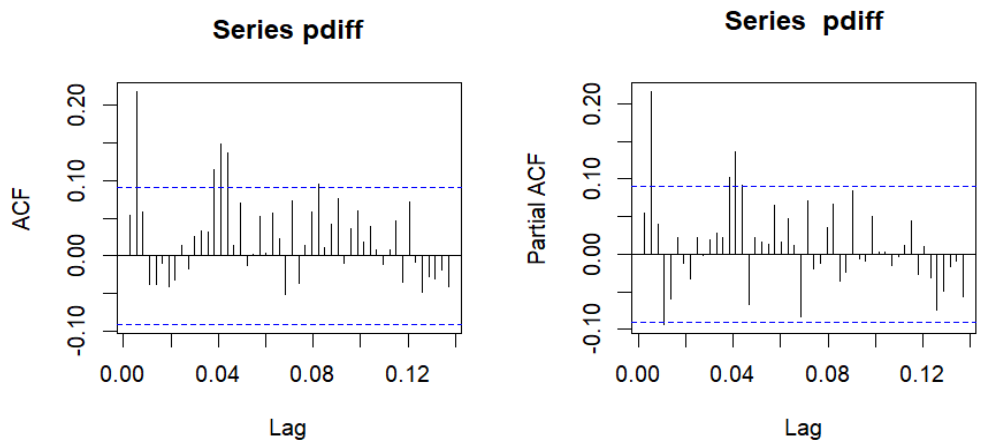

รูปที่ 5 : ACF และ PACF ของราคาทองคำรายวัน (stationary)

2.1. วิเคราะห์จาก ACF และ PACF

- **วิธีเลือกค่าพารามิเตอร์ p และ q**
  - หาก PACF ตัดที่ lag p และ ACF ลดลงเรื่อย ๆ ⟶ เลือก AR(p)
  - หาก ACF ตัดที่ lag q และ PACF ลดลงเรื่อย ๆ ⟶ เลือก MA(q)
  - หาก ACF และ PACF ลดลงทั้งคู่ ⟶ เลือก ARMA(p, q)

2.2. วิเคราะห์จากการใช้เกณฑ์ Information Criteria (IC)

- **วิธีเลือก AIC และ BIC :**
  - เราจะเลือกโมเดลที่ให้ ค่า AIC และ BIC ต่ำที่สุด เมื่อเปรียบเทียบกับโมเดลอื่น ๆ
  - หาก AIC และ BIC เลือกโมเดลเดียวกัน ถือว่าเป็นโมเดลที่เหมาะสมที่สุด
  - หาก AIC และ BIC เลือกโมเดลที่ต่างกัน ต้องพิจารณาวัตถุประสงค์ของการพยากรณ์

เราจะค้นหาค่าพารามิเตอร์ของแบบจำลอง (p, d, q) เพื่อหาโมเดลที่เหมาะสมที่สุด ดังต่อไปนี้

- **วิเคราะห์จาก ACF และ PACF ได้ดังนี้**

พบว่า ACF มีค่าเป็นจาก 0 อย่างมีนัยสำคัญหลัง lag ต้น ๆ (MA) และPACF มีค่าเป็นจาก 0 อย่างมีนัยสำคัญหลัง lag ต้น ๆ(AR) จึงพิจารณาตัวแบบ AR (2) และ MA (2) โดยใช้เกณฑ์ AIC และ BIC เพื่อเลือกโมเดลที่เหมาะสมที่สุด

ซึ่งได้ว่า:

- **ARIMA (2,1,2)**

พารามิเตอร์ : p = 2, d =1, q= 2

AIC	BIC	RMSE	MAE
1269.4	1290.09	0.9389	0.7376

ตารางที่ 3 : เกณฑ์การประเมิน ARIMA (2,1,2)

ตัวแบบที่ได้ คือ $Y'_t = \varphi_1 Y'_{t-1} + \varphi_2 Y'_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$

- **วิเคราะห์จากการใช้เกณฑ์ Information Criteria (IC) ได้ดังนี้**

พบว่า เมื่อใช้ฟังก์ชัน auto.arima เลือกตัวแบบที่มี AIC และ BIC ต่ำที่สุด พบว่า :

- **ARIMA (1,1,3)**

พารามิเตอร์ : p = 1, d =1, q= 3

AIC	BIC	RMSE	MAE
1265.16	1285.85	0.9346	0.7321

ตารางที่ 4 : เกณฑ์การประเมิน ARIMA (1,1,3)

ตัวแบบที่ได้ คือ $Y'_t = \varphi_1 Y'_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \theta_3 \varepsilon_{t-3}$

```
# ข้อที่ 2
model212 = Arima(pdiff, order = c(2,1,2))  # เลือกโมเดลจากการดู ACF และ PACF
model113 = Arima(pdiff, order = c(1,1,3))  # เลือกโมเดลจากการดู auto.arima

#หาโมเดลที่เหมาสมแบบใช้ auto.arima
auto.arima(pdiff, d = 1,test = "adf", trace = TRUE, seasonal = FALSE, ic = "aic"
           , stepwise = FALSE)
auto.arima(pdiff, d = 1,test = "adf", trace = TRUE, seasonal = FALSE, ic = "bic"
           , stepwise = FALSE)
# aic = 1,1,3 // bic = 1,1,3
```

3.

Model Diagnostic

3.1. ตรวจสอบความเหมาะสมของตัวแบบ

หลังจากได้โมเดลจากการวิเคราะห์เบื้องต้น เราจึงเข้าสู่ขั้นตอนการตรวจสอบความเหมาะสมของตัวแบบ เพื่อพิจารณา ว่าโมเดลใดเหมาะสมที่สุด โดยจะเน้นการวิเคราะห์ Residuals ของแต่ละโมเดลว่ามีลักษณะเป็น White Noise หรือไม่

- **ARIMA (2,1,2)**

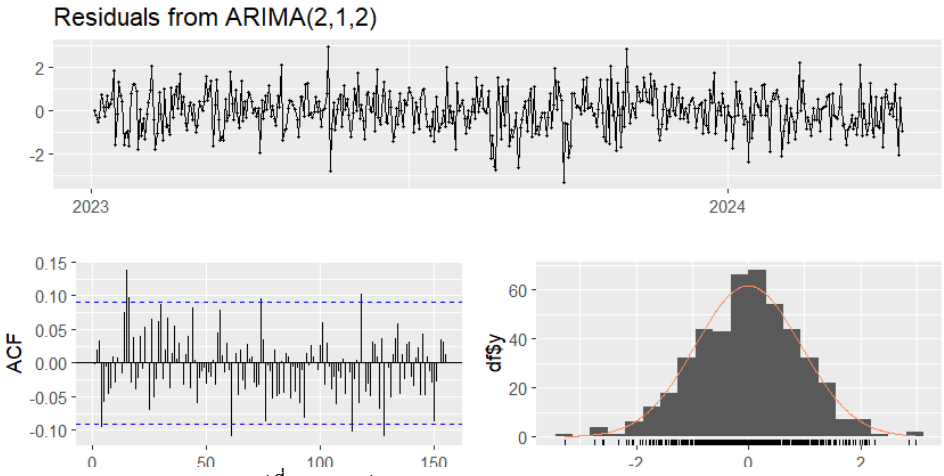

รูปที่ 6 : กราฟ check residuals ของ ARIMA (2,1,2)

- กราฟ Residuals พบว่าค่า Residuals เคลื่อนไหวรอบเส้น 0 และเคลื่อนไหวในกรอบคงที่ ดังนั้น Residuals มีค่าเฉลี่ยเป็น 0 และค่าแปรปรวนคงที่

- กราฟ Histogram พบว่าฮิสโตแกรมมีลักษณะเป็นรูปโค้งระฆังคว่ำ และสมมาตรที่ 0 ดังนั้น Residuals มีการแจกแจงปกติ

- กราฟ ACF พบว่า ส่วนใหญ่ มีค่าเป็น 0 เนื่องจากอยู่ภายในกรอบของช่วงความเชื่อมั่น อย่างไรก็ตาม มีบาง lag ที่มีค่า $\neq$ 0 อย่างมีนัยสำคัญจึงทำการทดสอบ ACF ในภาพรวมด้วย Ljung-Box test

สมมติฐาน

π_0 : $p_1 = p_2 = \ldots\ldots = p_{50} = 0$ $\longrightarrow$ (เป็น White Noise)

π_A : มี $p_i \neq 0$ อย่างน้อย 1ค่า $\longrightarrow$ (ไม่เป็น White Noise)

ผลลัพธ์จาก Ljung-Box test

p-value = 0.1538 > α = 0.05

จึงยอมรับ π_0 แสดงว่า ACF ทั้ง 50 lag เป็น 0 อย่างมีนัยสำคัญ

ดังนั้น แสดงว่า Residuals มีลักษณะเป็น White noise แสดงว่าตัวแบบ ARIMA(2,1,2) เหมาะสม

➢ **ARIMA (1,1,3)**

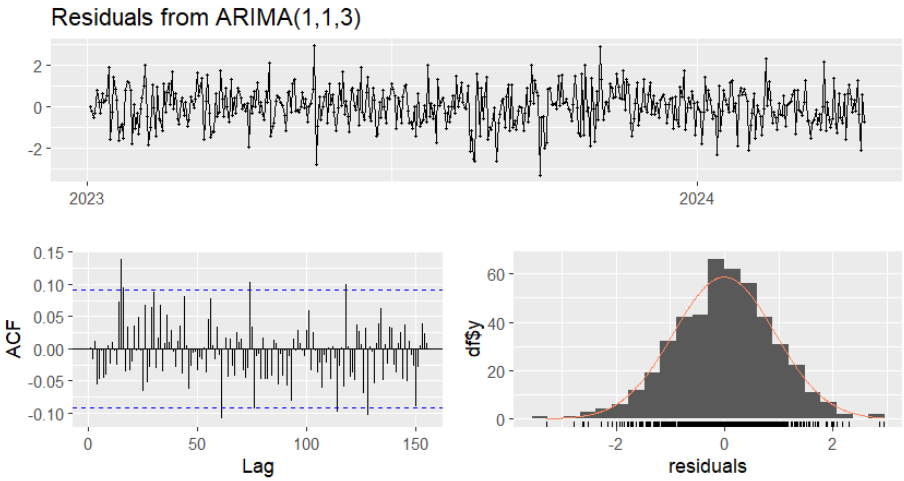

- กราฟ Residuals พบว่าค่า Residuals เคลื่อนไหวรอบเส้น 0 และเคลื่อนไหวในกรอบคงที่ ดังนั้น Residuals มีค่าเฉลี่ยเป็น 0 และค่าแปรปรวนคงที่

- กราฟ Histogram พบว่าฮิสโตแกรมมีลักษณะเป็นรูปโค้งระฆังคว่ำ และสมมาตรที่ 0 ดังนั้น Residuals มีการแจกแจงปกติ

- กราฟ ACF พบว่า ส่วนใหญ่ มีค่าเป็น 0 เนื่องจากอยู่ภายในกรอบของช่วงความเชื่อมั่น อย่างไรก็ตาม มีบาง lag ที่มีค่า $\neq$ 0 อย่างมีนัยสำคัญจึงทำการทดสอบ ACF ในภาพรวมด้วย Ljung-Box test

สมมติฐาน

π_0 : $p_1 = p_2 = \ldots\ldots = p_{50} = 0$ $\longrightarrow$ (เป็น White Noise)

π_A : มี $p_i \neq 0$ อย่างน้อย 1ค่า $\longrightarrow$ (ไม่เป็น White Noise)

ผลลัพธ์จาก Ljung-Box test

p-value = 0.2878 > α = 0.05

จึงยอมรับ π_0 แสดงว่า ACF ทั้ง 50 lag เป็น 0 อย่างมีนัยสำคัญ

ดังนั้น แสดงว่า Residuals มีลักษณะเป็น White noise แสดงว่าตัวแบบ ARIMA(1,1,3) เหมาะสม

```
# ข้อที่ 3: ตรวจสอบโมเดล
# ตรวจสอบ Residuals
checkresiduals(model212, 50, test = "LB", plot = TRUE)
checkresiduals(modelc, 50, test = "LB", plot = TRUE)

# คำนวณค่าความผิดพลาด
accuracy(model212)
accuracy(model113)

#MSE
MSE212 = 0.938857^2
MSE113 = 0.9346177^2
#สรุปเลือกAIC = 1,1,3
```

3.2.

เปรียบเทียบความคลาดเคลื่อนของการพยากรณ์จากตัวแบบที่ได้

เนื่องจากทั้งสองตัวแบบผ่านการตรวจสอบ Residuals และเป็น White Noise เราจึงจะใช้ความคลาดเคลื่อนของการพยากรณ์เป็นเกณฑ์ในการคัดเลือกตัวแบบที่ดีที่สุด โดยใช้ Mean square error (MSE), Root Mean Squared Error (RMSE), และ Mean Absolute Error (MAE) เพื่อประเมินความแม่นยำของการพยากรณ์

Model	**MSE**	**RMSE**	**MAE**
ARIMA (1,1,3)	0.8735	0.9346	0.7321
ARIMA (2,1,2)	0.8815	0.9388	0.7376

ตารางที่ *5* : เปรียบเทียบความคลาดเคลื่อนของการพยากรณ์จากตัวแบบที่ได้

จากการเปรียบเทียบพบว่า MSE , RMSE และ MAEของ ARIMA (1,1,3) น้อยกว่า ARIMA (2,1,2)

ดังนั้น จึงเลือกตัวแบบ ARIMA (1,1,3)

4. Forecasting

การ predict เหมาะสำหรับการพยากรณ์ช่วงสั้นที่มีข้อมูลต่อเนื่อง และการ forecast เหมาะสำหรับการพยากรณ์ล่วงหน้าพร้อมช่วงความเชื่อมั่น

- **การพยากรณ์ตัวแบบ ARIMA (1,1,3)**

ตัวแบบที่ได้ คือ $Y'_t = \varphi_1 Y'_{t-1} + \varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2} + \theta_3\varepsilon_{t-3}$

4.1. พยากรณ์ราคาทองของวันที่ 11 - 20 เมษายน 2024 เพื่อเปรียบเทียบกับข้อมูลจริง จึงเลือกใช้คำสั่ง predict เพื่อคำนวณค่าความคลาดเคลื่อน

วันที่	ข้อมูลจริง (gold_forecast)	พยากรณ์ราคาทอง วันที่ 11 - 20 เมษายน 2024	ค่าความคลาดเคลื่อน
11	64045.62891	64045.220	0.409
12	64044.13345	64044.960	-0.827
13	64043.57917	64044.840	-1.261
14	64043.93316	64044.740	-0.807
15	64043.21626	64044.650	-1.434
16	64041.76534	64044.560	-2.795
17	64043.41569	64044.470	-1.054
18	64044.57752	64044.380	0.198
19	64044.57209	64044.290	0.282
20	64043.15705	64044.200	-1.043

ตารางที่ *6* : เปรียบเทียบกับข้อมูลจริง กับค่าพยากรณ์ราคาทอง วันที่ 11 - 20 เมษายน 2024 เพื่อดูค่าความคลาดเคลื่อน

4.2. การพยากรณ์ช่วงวันที่ 21–30 เมษายน 2024 ซึ่งไม่มีข้อมูลจริง จึงใช้ forecast เพื่อพยากรณ์ล่วงหน้าพร้อมช่วงความเชื่อมั่น

วันที่	ข้อมูลจริง (gold_forecast)	พยากรณ์ราคาทอง วันที่ 21 - 30 เมษายน 2024
21	-	64044.15
22	-	64043.89
23	-	64043.77
24	-	64043.67
25	-	64043.58
26	-	64043.49
27	-	64043.40
28	-	64043.31
29	-	64043.22
30	-	64043.13

ตารางที่ 7 : ค่าพยากรณ์ราคาทอง วันที่ 21 - 30 เมษายน 2024

4.3. กราฟการพยากรณ์ช่วงวันที่ 11–30 เมษายน 2024 เพื่อดูภาพรวมของการพยากรณ์

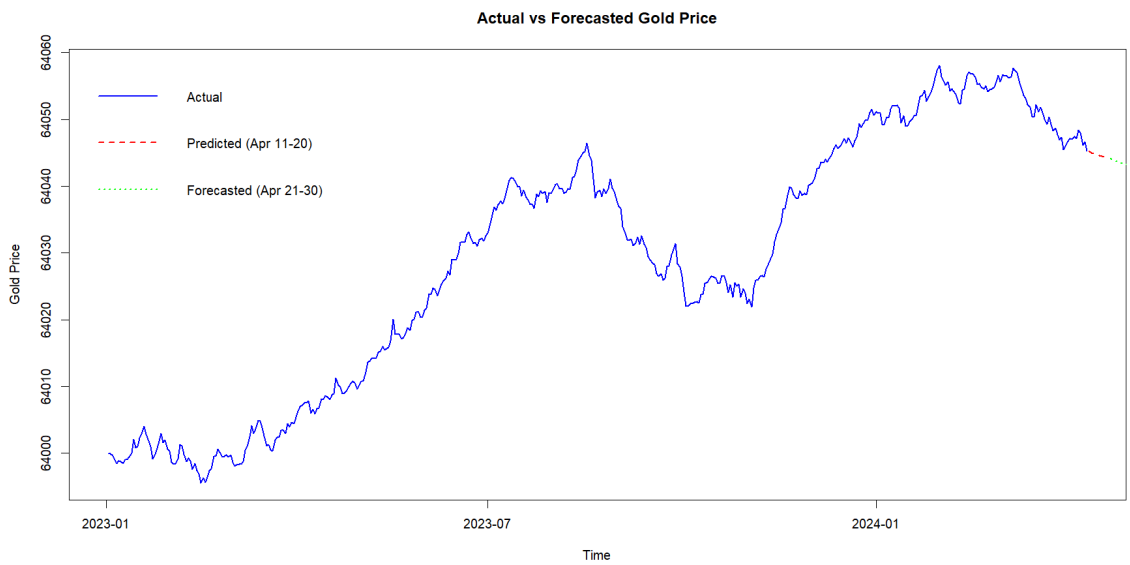

รูปที่ 8 : กราฟพยากรณ์ราคาทอง วันที่ 10 - 30 เมษายน 2024

จากกราฟ จะเห็นว่าค่าพยากรณ์ในช่วงวันที่ 11-20 เมษายน มีแนวโน้มสอดคล้องกับข้อมูลจริง และค่าพยากรณ์ในช่วงวันที่ 21-30 เมษายนยังคงมีเสถียรภาพ ไม่มีความผันผวนสูง

ข้อเสนอแนะเพิ่มเติม

- หากต้องการให้พยากรณ์สะท้อนความผันผวนมากขึ้น อาจพิจารณา **SARIMA (Seasonal ARIMA)** หรือใช้ตัวแบบ GARCH เพื่อจัดการความผันผวนของข้อมูล

```
#==============================================================================#
# ข้อที่ 4: พยากรณ์ 11 - 20 เม.ย. (ใช้ predict())
predict_10_days = predict(model113, n.ahead = 10)

# คืนค่าพยากรณ์กลับไปยังระดับเดิม
last_value = as.numeric(tail(Price_Gold, 1))  # ค่าล่าสุดของข้อมูลจริง
predict_10_days_original = last_value + cumsum(predict_10_days$pred)
predict_10_days_original
#==============================================================================#
# พยากรณ์ 21 - 30 เม.ย. (ใช้ forecast())
forecast_10_days = forecast(model113, h = 10)

# **ใช้ค่าล่าสุดจากพยากรณ์ 11 - 20 เม.ย.**
forecast_next_10_days_original = tail(predict_10_days_original, 1) + cumsum(forecast_10_days$mean)
forecast_next_10_days_original
#==============================================================================#
# สร้างกราฟ
# เวลาของข้อมูลจริง
time_actual = seq(from = as.Date("2023-01-02"),
                  by = "day", length.out = length(Price_Gold))
# เวลาของการพยากรณ์ช่วง 11 - 30 เม.ย.
time_forecast_10_days = seq(from = as.Date("2024-04-11"), by = "day",
                            length.out = length(predict_10_days_original))
time_forecast_next_10_days = seq(from = as.Date("2024-04-21"), by = "day",
                                 length.out = length(forecast_next_10_days_original))
# พล็อตค่าจริง
plot(time_actual, Price_Gold, type="l", col="blue", lwd=2, xlab="Time", ylab="Gold Price",
     main="Actual vs Forecasted Gold Price",
     ylim = range(c(Price_Gold, predict_10_days_original, forecast_next_10_days_original)))

# พล็อตค่าพยากรณ์ 11 - 20 เม.ย.
lines(time_forecast_10_days, predict_10_days_original, col="red", lwd=2, lty=2)
# พล็อตค่าพยากรณ์ 21 - 30 เม.ย.
lines(time_forecast_next_10_days, forecast_next_10_days_original, col="green", lwd=2, lty=3)
# เพิ่มคำอธิบายในกราฟ
legend("topleft", legend=c("Actual", "Predicted (Apr 11-20)", "Forecasted (Apr 21-30)"),
       col=c("blue", "red", "green"), lty=c(1,2,3), lwd=2, bty="n")
```

ผลลัพธ์ของการพยากรณ์

```
> # ข้อที่ 4: พยากรณ์ 11 - 20 เม.ย. (ใช้ predict())
> predict_10_days = predict(model113, n.ahead = 10)
> # คืนค่าพยากรณ์กลับไปยังระดับเดิม
> last_value = as.numeric(tail(Price_Gold, 1))  # ค่าล่าสุดของข้อมูลจริง
> predict_10_days_original = last_value + cumsum(predict_10_days$pred)
> predict_10_days_original
 [1] 64045.22 64044.96 64044.84 64044.74 64044.65 64044.56 64044.47 64044.38 64044.29 64044.20
> #==============================================================================#
> # พยากรณ์ 21 - 30 เม.ย. (ใช้ forecast())
> forecast_10_days = forecast(model113, h = 10)
> # **ใช้ค่าล่าสุดจากพยากรณ์ 11 - 20 เม.ย.**
> forecast_next_10_days_original = tail(predict_10_days_original, 1) + cumsum(forecast_10_days$mean)
> forecast_next_10_days_original
 [1] 64044.15 64043.89 64043.77 64043.67 64043.58 64043.49 64043.40 64043.31 64043.22 64043.13
```