



MOOC Student Analytics

Merged learner behavior, segmentation, supervised prediction, deep learning and LLM evidence

OUTLINE

ระยะที่ 1: การธรรมาภิบาลปัญหาและรากฐานข้อมูล (Problem Governance & Data Foundation)

- 1.การนิยามโจทย์และธรรมาภิบาล : การกำหนดเป้าหมาย, หน่วยในการวิเคราะห์, ประเภทของงาน , ตัวแปรเป้าหมาย, เกณฑ์ความสำเร็จ และธรรมาภิบาลข้อมูล
- 2.การรวบรวมข้อมูล ที่มา และการรวบรวมสื่อ : การบันทึกแหล่งที่มา, การจัดการข้อมูลหลายรูปแบบ และกระบวนการแปลงวิดีโอเป็นข้อความสำหรับ LLM/NLP
- 3.การควบคุมคุณภาพและการทำความสะอาดข้อมูล : การควบคุมเพื่อป้องกันการรั่วไหลของข้อมูล, การวิเคราะห์ค่าว่าง, การตรวจคำสั่งและเงื่อนไขตามกฎหมายธุรกิจ และการบันทึกประวัติการแก้ไขข้อมูล

ระยะที่ 2: การวิเคราะห์เชิงสำรวจและการทบทวนหลักฐาน (Exploratory Analysis & Evidence Review)

- 4.การวิเคราะห์ข้อมูลเชิงสำรวจ (EDA) : การสำรวจคุณลักษณะทั้งหมด, การกระจายตัวของข้อมูลเชิงตัวเลข/กลุ่ม,อนุกรมเวลา, ความสัมพันธ์ระหว่างตัวแปร, ค่าผิดปกติ, โครงสร้างมิติข้อมูล และการวัดความเป็นไปได้ในการจัดกลุ่ม
- 5.การทบทวนวรรณกรรมและประเมินหลักฐาน : การรวบรวมงานวิจัยอ้างอิง งานวิจัยที่เกี่ยวข้อง และเกณฑ์มาตรฐานทางการ เพื่อสนับสนุนการเลือกโมเดล

ระยะที่ 3: การพัฒนาฟีเจอร์และโมเดล (Feature & Model Development)

- 6.วิศวกรรมและการคัดเลือกฟีเจอร์ : การแบ่งข้อมูลก่อนการสเกล, การสร้างฟีเจอร์ใหม่, การแปลงรูปข้อมูล, การคัดเลือกฟีเจอร์ และการทดสอบตัดฟีเจอร์
- 7.การเลือกโมเดล การฝึกฝน และการติดตามการทดลอง : การเลือกตระกูลโมเดล (Classification, Clustering, Regression, Time-series, NLP/LLM), กลยุทธ์การแบ่งข้อมูล, การจัดการคลาสไม่สมดุล, การปรับจูนไฮเปอร์พารามิเตอร์ และการบันทึกประวัติการทดลอง

ระยะที่ 4: การประเมินผล ความสามารถในการอธิบาย และการตัดสินใจ (Evaluation, Explainability & Decision-Making)


8. การประเมินผลโมเดล การปรับแต่ง และการวิเคราะห์ข้อผิดพลาด : การตั้งโมเดลฐาน, ตัววัดประสิทธิภาพตามประเภทงาน (Classification/Regression/Clustering/LLM Metrics), การปรับความแม่นยำและจุดตัด, การวิเคราะห์ข้อผิดพลาด และการตรวจสอบความเท่าเทียม

ระยะที่ 5: การปรับใช้ การสื่อสาร และการบริหารจัดการวงจรชีวิต (Deployment, Communication & Lifecycle Management)

- 9.การปรับใช้งานและการตรวจสอบระดับปฏิบัติการ : การสร้างระบบท่อส่งข้อมูลประมวลผล, การตรวจสอบสกีมนำเข้า, การทดสอบระบบก่อนขึ้นจริง และการจัดทำเอกสารกำกับโมเดล
- 10.การสื่อสารและการรายงานผลผ่าน HTML โต้ตอบ : การสร้างรายงานสรุปและแดชบอร์ด 11 ขั้นตอน การรองรับ 2 ภาษา (TH/EN) และการจำลองสถานการณ์
- 11.การติดตามผล การบำรุงรักษา และวงจรสะท้อนกลับ : การวัดดัชนีความเสถียรของประชากร, การตรวจจับการถดถอยของโมเดล, เงื่อนไขการแจ้งเตือน และนโยบายการฝึกโมเดลซ้ำ

Data Set

แหล่งข้อมูล :



Filename: big_student_clear_third_version.csv

- 416,921 แถว
- 21 คอลัมน์

Exact duplicate = 0

Filename: HXPC13_DI_v3_11-13-2019.csv

- 338,223 แถว
- 20 คอลัมน์

Exact duplicate = 0

Data Set : big_student_clear_third_version.csv

416,921 แถว 21 คอลัมน์

1.institute : 2 values

- MITx = 240,119
- HarvardX = 176,802

2.course_id : 13 values

3.year : 2 values

- 2013 = 236,860
- 2012 = 180,061

4.semester : 3

- Spring = 244,746
- Fall = 152,292
- Summer = 19,883

5.userid_DI :

• **416,921 values**

• **335,650 values ไม่ซ้ำ**

6.viewed : 2 values

- 1 = 296,320
- 0=120,601

7.explored : 2 values

- 1= 32,355
- 0 = 384,566

8.certified : 2 values

- 0 = 402,032 = No certified
- 1= 14,889 = Yes certified

9.final_cc_cname_DI : 34 values

10.LoE_DI : 5 values

- Bachelor's = 183,266
- Secondary = 124,140
- Master's = 89,492
- Doctorate = 10,237
- Less than Secondary = 9,786

11.gender : 3 values

- m = 292,466
- f = 101,240
- o = 4
- **NaN = 23,211 (5.567%)**

12.grade : [0-1]

13.start_time_DI

14.last_event_DI

15.nevents : 9,702 values

16.ndays_act : 152 values

17.nplay_video : 2,534 values

18.nchapters : 49 values

19.nforum_posts : [0-7]

20.incomplete_flag : 2 values

- 0 = 404,807
- 1= 12,114

21.age : [-1 - 82]

Data Set : HXPC13_DI_v3_11-13-2019.csv

338,223 แถว 20 คอลัมน์

1. **course_id** : 5 values
2. **userid_DI** :
 - 338,223 values
 - 301,609 values ไม่ซ้ำ
3. **registered** : 1 values
4. **viewed** : 2 values
 - 1 = 193,856
 - 0=1 144,367
5. **explored** : 2 values
 - 1= 20,624
 - 0 = 317,599
6. **certified** : 2 values
 - 0 = 331,653 = No certified
 - 1= 6,570 = Yes certified
7. **final_cc_cname_DI** : 34 values
8. **LoE_DI** : 5 values
 - Bachelor's = 119,511
 - Secondary = 85,608
 - Master's = 71,702
 - Doctorate = 9,354
 - Less than Secondary = 7,929
 - **NaN = 44,119 (13.044%)**

10. **YoB** : 78 values
11. **gender** : 3 values
 - m = 208,184
 - f = 97,061
 - o = 17
 - **NaN = 32,961 (9.75%)**
12. **grade** : [0-1.01]
 - **Missing 25,890 (7.65%)**
13. **start_time_DI**
14. **last_event_DI**
 - **Missing 152,231 (45.01%)**
15. **nevents** : 5,133 values
 - **Missing 159,278 (47.09%)**
16. **ndays_act** : 125 values
 - **Missing 142,510 (42.13%)**
17. **nplay_video** : 1,836 values
 - **Missing 304,946 (90.16%)**
18. **nchapters** : 34 values
 - **Missing 144,465 (42.71%)**
19. **nforum_posts** : [0-7]
20. **roles** : 0
 - **Missing 338,223 (100.000%)**
21. **incomplete_flag** : 1 values
 - 1= 77,385
 - **Missing 260,838 (77.12%)**

การทำความสะอาดข้อมูล

สรุปกฎสำคัญที่ใช้ก่อนสร้างฟีเจอร์และเทรนโมเดล

ประเด็น	วิธีการ	จำนวนที่กระทบ
การทำความสะอาดข้อมูลระดับแหล่งที่มา (Source-first cleaning)	ทำความสะอาดข้อมูลแต่ละแหล่งให้เรียบร้อยก่อนนำมารวมกัน (Reconciliation)	755,144
ความซ้ำซ้อนระหว่างแหล่งข้อมูล (Cross-source overlap)	รวมข้อมูลแบบต่อเติมค่าว่าง (Non-null coalescing) โดยยึดแหล่งข้อมูลทางการเป็นหลัก และจับคู่ด้วยรหัสการลงทะเบียนที่ตรงกันพอดี	180,084
ค่าตัวแทนกรณีไม่มีวิดีโอ (Video sentinel)	เปลี่ยนค่า 197757 ให้เป็นค่าที่สูญหาย (Missing) ก่อนทำการรวมข้อมูล	255,528
อายุไม่ถูกต้อง (Invalid age)	เปลี่ยนค่าที่ไม่ถูกต้องให้เป็นค่าที่สูญหาย (Missing) ก่อนทำการรวมข้อมูล	745
วันที่สลับกัน (Reversed dates)	สลับตำแหน่งคู่วันที่ให้ถูกต้องภายในแต่ละแหล่งข้อมูลก่อนทำการรวม	1,846
ความสอดคล้องของผลลัพธ์ (Outcome consistency)	แยกข้อมูลที่ขัดแย้งกันไว้นอกกลุ่ม (Quarantine) และคัดป้ายกำกับที่ไม่ถูกต้องออกเฉพาะจากการพิจารณาสิทธิ์ในแบบจำลอง Supervised Learning	78
การรวบรวมข้อมูลระดับนักเรียน (Student aggregation)	สรุปข้อมูลเหลือ 1 แถวต่อ 1 รหัสผู้ใช้ (userid_DI) หลังจากการปรับปรุงรวมข้อมูลเสร็จสมบูรณ์	446,766

ข้อสรุป

- ข้อมูลทำความสะอาดแบบ source-first แล้วจึง reconcile ข้ามแหล่งข้อมูล
- ค่าผิดปกติ เช่น video sentinel, invalid age, reversed dates และ outcome contradiction ถูกบันทึกเป็น audit trail
- ผลลัพธ์สุดท้ายใช้ student aggregation หนึ่งคนต่อหนึ่งแถวสำหรับงานวิเคราะห์หลัก

คำถามวิจัยและขอบเขตงาน

นิยามปัญหาและการจัดวางงานตาม data science workflow

1 นักศึกษา

หน่วยวิเคราะห์

446,766

จำนวนหลังรวมข้อมูล

4 งาน

Track ที่วิเคราะห์


Certificate

เป้าหมายสำคัญ

- Unsupervised ใช้พีเจอร์ฟฤติกรรมเพื่อแบ่งกลุ่มผู้เรียนและอธิบาย Persona โดยไม่ใช้ target label
- Supervised และ Deep Learning ใช้พีเจอร์ที่ผ่านการคัดกรองเพื่อทำนายการได้รับใบรับรอง
- LLM/Transformer แปลงหนึ่งแถวนักศึกษาเป็นประโยคเชิงฟฤติกรรมก่อนสร้าง embedding และเทรน (Train) classifier

EDA: การกระจายและคุณภาพข้อมูล



ตรวจ distribution, missing, zero, sparsity และ outlier ก่อนสร้างโมเดล



กราฟนี้ใช้ดูรูปทรงการกระจายของฟีเจอร์พฤติกรรมทั้งหมด เพื่อแยกฟีเจอร์ที่เบ้มาก มีศูนย์จำนวนมาก หรือมีค่าผิดปกติสูง ก่อนตัดสินใจแปลงค่าและคัดเลือกฟีเจอร์

EDA: ความสัมพันธ์และความผิดปกติของพฤติกรรม

ใช้ correlation และ outlier diagnostics เพื่อตรวจความซ้ำซ้อนของฟีเจอร์




Correlation ช่วยระบุฟีเจอร์ที่สัมพันธ์กันสูง ส่วน **outlier diagnostics** ใช้ตรวจผู้เรียนที่มีกิจกรรมสูงผิดปกติ เพื่อป้องกันไม่ให้โมเดลถูกครอบงำจากค่าปลายหาง

แบ่งข้อมูล

งาน	Train	Validation	Test	หมายเหตุ	งาน
Supervised	312,706	67,009	67,009	70/15/15	Supervised
Deep Learning	312,706	67,009	67,009	ใช้ split เดียวกับ Supervised	Deep Learning
LLM / Transformer	8,400	1,800	1,800	ใช้ sample 12,000	LLM / Transformer
Unsupervised	-	-	-	ใช้ metric sample 12,000 และ silhouette sample 5,000	Unsupervised

การเลือกจำนวนกลุ่ม K

เลือก K จากหลักฐานหลายตัวชี้วัด ไม่ยึดเฉพาะ Elbow



5

K ที่เลือก

0.4275

Silhouette

0.8827

Davies-Bouldin



0.9935

ARI stability

เกณฑ์ที่ใช้ร่วมกันคือ Silhouette, Davies-Bouldin, Calinski-Harabasz, ARI stability, inertia และ Gap statistic
ผลสุดท้ายใช้ K=5 เพราะให้สมดุลระหว่างคุณภาพการแบ่งกลุ่มและความเสถียรของกลุ่ม

Traditional Unsupervised : ผลเปรียบเทียบโมเดล

Feature Importance ของ Unsupervised




Model family	K	Silhouette	Davies-Bouldin	Calinski-Harabasz	Resample ARI	Smallest cluster %	Largest cluster %	Runtime sec
K-Means	5	0.4276	0.8827	16,546.02	0.9931	13.225	29.2917	2.2843
MiniBatch K-Means	5	0.4265	0.9031	16,475.09	0.7243	14.2417	29.3167	0.475
Gaussian Mixture	5	0.346	1.1673	9,992.50	0.9596	1.625	34.2417	2.1303
BIRCH	5	—	—	—	1	—	—	0.8223

"การเลือก K=5 มีความสมดุลสูงสุดระหว่างคุณภาพการจัดกลุ่ม (Silhouette = 0.428) ความเสถียรของกลุ่ม (ARI = 0.9935) และการลดลงของ Inertia ตามกฎ Gap One-SE Rule"

Persona ผู้เรียน 5 กลุ่ม

สัดส่วนและพฤติกรรมเฉลี่ยของแต่ละกลุ่ม




กลุ่ม	ชื่อกลุ่ม	จำนวน	สัดส่วน	พฤติกรรมเฉลี่ย	ระดับ
C0	กลุ่มพฤติกรรมระดับปานกลาง	46,296	13.8%	0.444	พฤติกรรมระดับปานกลาง
C1	กลุ่มกิจกรรมสูงมาก มีโอกาสผ่านการรับรองสูง	62,225	18.5%	0.784	พฤติกรรมระดับสูง
C2	กลุ่มพฤติกรรมระดับปานกลางอย่างสม่ำเสมอ	55,365	16.5%	0.453	พฤติกรรมระดับปานกลาง
C3	กลุ่มใหญ่ที่สุด กิจกรรมต่ำ เสี่ยงต่อการ drop-out	97,719	29.1%	0.277	พฤติกรรมระดับต่ำ
C4	กลุ่มกิจกรรมปานกลางค่อนข้างสูง	74,045	22.1%	0.613	พฤติกรรมระดับปานกลางค่อนข้างสูง


“กลุ่มที่ใหญ่ที่สุดคือ Cluster 3 มี 97,719 คน หรือ 29.1% และมีระดับพฤติกรรมเฉลี่ยต่ำกว่าอีกหลายกลุ่ม ขณะที่ Cluster 1 มีพฤติกรรมสูงสุดและคิดเป็น 18.5% ของประชากร”

โปรไฟล์พฤติกรรมของ Persona

เรดาร์และ PCA ใช้อธิบายลักษณะเฉพาะของแต่ละกลุ่ม



“เรดาร์แสดงจุดแข็งของแต่ละ Persona เช่น event, active days, chapters และ forum posts ส่วน PCA แสดงการแยกตัวของกลุ่มในพื้นที่พฤติกรรมหลายมิติ”




“3D PCA แสดงการแยกตัวของทั้ง 5 กลุ่มในพื้นที่พฤติกรรมได้อย่างชัดเจน โดยมี PC1 (84.6%) เป็นแกนหลักที่อธิบายระดับการมีส่วนร่วมของผู้เรียน”

Supervised Learning Classification

ทำนายการได้รับใบรับรองจากฟีเจอร์ที่ผ่านการควบคุม target leakage

Feature Importance ของ Supervised Learning



"ฟีเจอร์พฤติกรรมเกี่ยวกับการเข้าเรียนบทเรียน (max_chapters_single_course, total_chapters) และจำนวนวันที่เข้าใช้งาน (active_days) เป็นตัวแปรที่มีอิทธิพลมากที่สุดในการทำนายการได้รับใบรับรอง"

Random Forest

Champion

0.8615

PR-AUC

0.8619


Recall

0.8014

F1-score

98.65%


Accuracy



"Random Forest ให้สมรรถนะระหว่าง PR-AUC, recall และ F1 ดีกว่า Dummy baseline อย่างชัดเจน เหมาะกับปัญหาที่ class positive มีสัดส่วนน้อย"

Supervised : Confusion Matrix และ Error Analysis

ตรวจสอบ false positive และ false negative เพื่อประเมินผลอัลกอริทึม test set



"โมเดล Champion สามารถจำกัด False Negative (ผู้เรียนที่ควรผ่านแต่ทำนายว่าไม่ผ่าน) ให้อยู่ในระดับต่ำมาก (~293 คน จาก 65,000+ คน) ช่วยให้ระบบแจ้งเตือนไม่ตกหล่นผู้เรียนกลุ่มเสี่ยง"

Supervised Learning Classification

ใช้ MLP หลายสถาปัตยกรรมเพื่อกำหนด certification

model_name	test_pr_auc	test_roc_auc	test_accuracy	test_balanced_accuracy	test_precision	test_recall	test_f1	runtime_sec
Random Forest	0.8615	0.9956	0.9865	0.9262	0.7489	0.8619	0.8014	26.5305
Gradient Boosted Trees	0.8412	0.9957	0.9876	0.935	0.7649	0.8788	0.8179	2.9105
Extra Trees	0.8361	0.9943	0.9849	0.9176	0.7234	0.8458	0.7798	27.8185
Decision Tree	0.8036	0.985	0.9842	0.9275	0.7022	0.867	0.7759	2.4425
Logistic Regression	0.7752	0.9921	0.9818	0.9049	0.6737	0.8227	0.7408	6.8309
Linear SVM	0.7713	0.992	0.982	0.9057	0.6775	0.8241	0.7437	8.634
Gaussian Naive Bayes	0.4852	0.9744	0.969	0.9117	0.5057	0.8505	0.6343	0.1623
Dummy baseline	0.0317	0.5	0.9683	0.5	0	0	0	0.0055

โมเดลที่เลือก คือ Random Forest
ผลทดสอบได้ Test PR-AUC 0.8615 , Test ROC-AUC 0.9956 , Test Accuracy 98.65% , Balanced Accuracy 0.9262 , Precision 0.7489, Recall 0.8619 , F1 0.8014

Deep Learning Classification

ใช้ MLP หลายสถาปัตยกรรมเพื่อกำหนด certification

- Feature Importance ของ Deep Learning




MLP Neural Network Champion

0.8388 PR-AUC

0.8421 Recall

0.7917 F1-score


98.60 % Accuracy



โมเดล Deep Learning ที่ได้รับเลือก MLP Neural Network สามารถเรียนรู้ความสัมพันธ์ไม่เชิงเส้นระหว่างฟีเจอร์พฤติกรรมและทำนายผู้ได้รับใบรับรองได้อย่างแม่นยำ

Deep Learning : Confusion Matrix และ Error Analysis

ใช้ MLP หลายสถาปัตยกรรมเพื่อกำหนด certification



"โมเดล Champion สามารถจำกัด False Negative (ผู้เรียนที่ควรผ่านแต่ทำนายว่าไม่ผ่าน) ให้อยู่ในระดับต่ำมาก (~293 คน จาก 65,000+ คน) ช่วยให้ระบบแจ้งเตือนไม่ตกหล่นผู้เรียนกลุ่มเสี่ยง"

Deep Learning Classification

ใช้ MLP หลายสถาปัตยกรรมเพื่อกำหนด certification

model_name	family	test_pr_auc	test_roc_auc	test_accuracy	test_balanced_accuracy	test_precision	test_recall	test_f1	runtime_sec	epochs_or_ite_rations
MLP Neural Network (128, 64)	Neural Network Classifier	0.8388	0.9947	0.986	0.9164	0.747	0.8421	0.7917	12.2695	26
Regularized MLP (64, 32)	Neural Network Classifier	0.8359	0.9945	0.9853	0.914	0.7349	0.8378	0.783	10.4653	35
Deep MLP (128, 64, 32)	Neural Network Classifier	0.8302	0.9946	0.9856	0.9225	0.7329	0.8553	0.7894	8.5637	15
MLP Neural Network (64, 32)	Neural Network Classifier	0.8153	0.9937	0.9836	0.919	0.698	0.8501	0.7666	3.9024	12
MLP Neural Network (32)	Neural Network Classifier	0.8132	0.9933	0.9838	0.9175	0.7032	0.8468	0.7683	2.1502	11
MLP Tanh (64)	Neural Network Classifier	0.8114	0.9934	0.9844	0.9046	0.7239	0.8194	0.7687	2.9533	11

โมเดลที่เลือกคือ MLP Neural Network (128, 64). ผลทดสอบได้ PR-AUC 0.839, Recall 0.842 และ F1 0.792
จึงใช้เป็น deep learning challenger เทียบกับ supervised champion


LLM / Transformer Text Classification

แปลงหนึ่งแถวนักศึกษาเป็นข้อความเชิงพฤติกรรมก่อนเข้าโมเดล

กระบวนการ

- 1. สรุปลพฤติกรรมจากข้อมูลรายแถว
- 2. แปลงเป็นประโยคเชิงพฤติกรรม
- 3. สร้าง Transformer embedding
- 4. ทรู (Train) Logistic Regression หรือ classifier
- 5. วัดผลด้วย PR-AUC, ROC-AUC, Recall และ F1

• Feature importance ของ LLM / Transformer



DistilBERT + LR

Champion

0.725


PR-AUC

0.793

Recall

0.697


F1-score



"DistilBERT Embeddings สามารถแปลงประโยคพฤติกรรมผู้เรียนออกมาเป็นเวกเตอร์ที่แยกแยะกลุ่มเรียนผ่าน/ไม่ผ่านออกจากกันได้อย่างชัดเจนเหนือกว่าเทคนิค Lexical (TF-IDF) อย่างมีนัยสำคัญ"

LLM / Transformer : ผลลัพธ์และหลักฐาน

เปรียบเทียบ representation แบบ lexical baseline และ transformer embedding



LLM / Transformer : ผลลัพธ์และหลักฐาน

เปรียบเทียบ representation แบบ lexical baseline และ transformer embedding

Model	Representation	PR-AUC	ROC-AUC	Precision	Recall	F1	Runtime
TF-IDF Unigram + Logistic Regression	lexical NLP baseline	0.1552	0.8592	0.1089	0.1897	0.1384	0.2507
TF-IDF (1-2 grams) + Logistic Regression	lexical NLP baseline	0.37	0.9531	0.359	0.7241	0.48	0.4671
TF-IDF + Linear SVM	lexical NLP baseline	0.4153	0.9505	0.4815	0.4483	0.4643	1.2903
Sentence Transformer + Logistic Regression	frozen sentence transformer	0.4064	0.9683	0.3582	0.8276	0.5	758.3442
DistilBERT Embeddings + Logistic Regression	frozen transformer encoder	0.7247	0.9875	0.6216	0.7931	0.697	623.2175
MiniLM Embeddings + Logistic Regression	frozen sentence transformer	0.4494	0.9601	0.3269	0.5862	0.4198	26.1465
DistilGPT2 Embeddings + Logistic Regression	open-weight GPT-style frozen decoder	0.6556	0.9853	0.5732	0.8103	0.6714	326.5793

โมเดลที่เลือกคือ DistilBERT Embeddings + Logistic Regression
ผลทดสอบได้ PR-AUC 0.725, Recall 0.793 และ F1 0.697 จึงใช้เป็น LLM / Transformer champion สำหรับประมวลผลข้อมูลเชิงพฤติกรรมในรูปแบบข้อความ

ตารางเปรียบเทียบผลโมเดลหลัก


สรุป champion ของแต่ละงาน

Track	โมเดลที่เลือก	Metric หลัก	ค่า	Metric สนับสนุน
Traditional Unsupervised	K-Means, K=5	Silhouette	0.428	DB 0.883, ARI 0.993
Supervised	Random Forest	PR-AUC	0.861	Recall 0.862, F1 0.801
Deep Learning	MLP Neural Network (128, 64)	PR-AUC	0.839	Recall 0.842, F1 0.792
LLM / Transformer	DistilBERT Embeddings + Logistic Regression	PR-AUC	0.725	Recall 0.793, F1 0.697

- Supervised และ Deep Learning ให้ผลดีมากในงานทำนาย certification เพราะใช้ฟีเจอร์เชิงพฤติกรรมแบบมีโครงสร้าง
- LLM/Transformer มีบทบาทเป็นตัวแปลงข้อความเป็น embedding แล้วให้ classifier เรียนรู้ต่อ
- Unsupervised ใช้สำหรับอธิบาย Persona และ pattern discovery ไม่ใช่งานทำนาย target โดยตรง

ภาพรวมผลลัพธ์ทุก Track

กราฟรวมใช้เปรียบเทียบความเหมาะสมของวิธีวิเคราะห์แต่ละประเภท



Track	คำถามหลัก	คำตอบ
Unsupervised	ผู้เรียนควรแบ่งกี่กลุ่ม	K=5
Supervised	โมเดลทำนาย certification ที่ดีที่สุด	Random Forest
Deep	Neural network ทำได้ดีแค่ไหน	MLP 128/64 เป็น challenger
LLM	แปลงพฤติกรรมเป็นข้อความแล้วทำนายได้ไหม	DistilBERT + Logistic Regression ดีสุดใน text track

"Supervised Learning (Random Forest: 0.862) ให้ประสิทธิภาพการทำนาย Certification สูงที่สุดอย่างเด่นชัด เนื่องจากใช้ Structured Behavioral Features โดยตรง ขณะที่ LLM Track (0.725) เป็นทางเลือกใหม่สำหรับ Unstructured Text Data"

หมายเหตุการวัดผล:
Unsupervised Track: ตัวเลข 0.428 คือ Silhouette Score (วัดความแน่นหนาและการแยกกันของ Cluster)
Supervised / Deep Learning / LLM Track: ตัวเลขคือ Test PR-AUC (Area Under the Precision-Recall Curve) ซึ่งเลือกใช้เนื่องจากปัญหา Class Imbalance สูง (ผู้เรียนผ่านเกณฑ์ได้รับใบรับรองมีสัดส่วนน้อย)

ข้อสรุปจากผลวิเคราะห์

คำตอบหลักที่ได้จากข้อมูลและโมเดล

- ข้อมูลหลังทำความสะอาดและรวมแหล่งข้อมูลสามารถสร้าง student-level dataset ที่ใช้วิเคราะห์ได้ 446,766 คน
- การแบ่งกลุ่มผู้เรียนเหมาะกับ K=5 ตามผล Gap statistic และตัววัดสนับสนุนหลายตัว
- กลุ่ม Persona แสดงความต่างของกิจกรรมเรียน เช่น event, active days, chapters และ forum posts
- Random Forest เป็น supervised champion สำหรับทำนาย certification จากตารางผลปัจจุบัน
- Deep Learning ให้ผลใกล้เคียง supervised แต่ต้องใช้เวลาและการจูนมากกว่า
- LLM/Transformer track ทำงานได้ในรูปแบบ row-to-text embedding โดย DistilBERT + Logistic Regression ให้ผลดีที่สุดในกลุ่ม text model

ข้อจำกัดและข้อเสนอแนะ

ประเด็นที่ควรระวังเมื่อนำผลไปใช้งานจริง

ข้อจำกัด

- ข้อมูล MOOC มี class imbalance สูง จึงควรดู recall, F1 และ PR-AUC มากกว่า accuracy เพียงอย่างเดียว
- การแปลพฤติกรรมเป็นข้อความใน LLM track ขึ้นกับ template ประโยคที่ออกแบบ
- K ใน clustering เป็นผลจากเกณฑ์เชิงประจักษ์และการตีความ Persona ไม่ใช่ label จริงจากผู้สอน

ข้อเสนอแนะ

- ใช้ Persona เพื่อออกแบบการช่วยเหลือผู้เรียนต่างกลุ่ม เช่น กลุ่มกิจกรรมต่ำ และกลุ่มดูเนื้อหาไม่ต่อเนื่อง
- ติดตาม drift ของฟีเจอร์และ retrain เมื่อพฤติกรรมผู้เรียนเปลี่ยนจากชุดข้อมูลเดิม
- Early Warning System: นำ Random Forest (Supervised Champion) ไปปรับใช้เป็นระบบแจ้งเตือนความเสี่ยงผู้เรียนล่วงหน้า
- Personalized Nudging: นำผล 5 Personas ไปใช้ส่งข้อความกระตุ้นผู้เรียนกลุ่ม C3 และ C0/C2 เพื่อเพิ่มอัตราการเรียนจบ