

Student Performance & Behavior Dataset.

Presentation 2025

Presented By **Chutimon Nunthasena**



concept

1. สำรวจชุดข้อมูลและแสดงประเด็นที่นำไปสู่การตั้งสมมติฐาน
2. สมมติฐานเบื้องต้นสำหรับค้นพบความรู้จากชุดข้อมูลนั้น
3. การแก้ไข missing value
4. ต้องปรับชุดข้อมูลให้เป็น formal concept หรือไม่
5. เลือกเทคนิคแบบจำลองสำหรับค้นพบความรู้ตามสมมติฐาน
6. การดำเนินการเตรียมพร้อมชุดข้อมูลให้สามารถใช้งานเทคนิคนั้นได้
7. ผลลัพธ์จากแบบจำลองที่ครบถ้วนสำหรับเทคนิคนั้น
8. การตีความ หรือความรู้ที่สรุปได้จากผลลัพธ์ ตอบสมมติฐานของเราอย่างไร
9. ผลลัพธ์น่าพอใจหรือไม่? หรือยังมีประเด็นต่อเนื่องสำหรับทำ Data Science รอบต่อไปหรือไม่?

เป้าหมาย คือ

- ต้องการวิเคราะห์ปัจจัยที่มีผลต่อการสอบตก + สร้างระบบแจ้งเตือน โดยใช้ข้อมูลพฤติกรรมและสิ่งแวดล้อม



สำรวจชุดข้อมูลเบื้องต้น

Data Name : Student Performance & Behavior Dataset

รายละเอียดข้อมูล :

จำนวนระเบียน : 5,000 รายการ

จำนวนฟีเจอร์ : 23 ฟีเจอร์

ปัญหาที่พบ :

- Missing Values ในบางคอลัมน์
เช่น Attendance, Assignments_Avg,
Parent_Education_Level
- ตัวแปรบางตัวเป็นเชิงหมวดหมู่ที่อาจต้องแปลงเป็นตัวเลขก่อนวิเคราะห์

คลาสข้อมูล :

- มีคลาส แต่คลาสที่ใช้ในการเรียนรู้ของโมเดล ไม่ได้ใช้จาก Grade เดิมในชุดข้อมูลต้นฉบับแต่เป็นคลาสใหม่ที่สร้างขึ้น จากการรวมคะแนนย่อยของนักเรียน
ดังนี้ Attendance, Midterm_Score, Final_Score,
Assignments_Avg, Quizzes_Avg, Participation_Score,
Projects_Score



💡 ประเด็นที่นำไปสู่การตั้งสมมติฐาน 💡

พบประเด็นสำคัญหลายประการที่นำไปสู่การตั้งสมมติฐานได้แก่:

- 📊 ข้อมูลมีพีเจอร์เกี่ยวกับพฤติกรรมการณ์เรียน
เช่น การเข้าเรียน, ชั่วโมงเรียน, ความเครียด, การนอน ฯลฯ
- 📋 มีคะแนนย่อยหลายด้าน
เช่น งาน, แบบทดสอบ, สอบกลางภาค, ปลายภาค
- 🏠 มีข้อมูลสิ่งแวดล้อม
เช่น รายได้ครอบครัว และการศึกษาของผู้ปกครอง
- 🧠 เกรดในชุดข้อมูลสามารถใช้ระบุว่าคุณเรียน “สอบตก” ได้หรือไม่
- 🔍 ข้อมูลสาขาต่างๆ
เช่น วิศวกรรม, คอมพิวเตอร์ ฯลฯ ซึ่งอาจมีผลต่อผลการเรียน



สมมติฐานเบื้องต้นสำหรับค้นพบความรู้จากชุดข้อมูล

💡 สมมติฐาน 💡

"พฤติกรรมการณ์เรียนและปัจจัยด้านสิ่งแวดล้อมมีผลต่อการที่นักเรียนจะสอบตกหรือไม่"

โดยตั้งใจจะใช้โมเดล Machine Learning มาวิเคราะห์ว่า ปัจจัยใดที่มีผลต่อเกรดมากที่สุด และพัฒนาเป็นระบบ Early Warning สำหรับตรวจจับนักเรียนที่มีความเสี่ยงสอบตก หากรู้ปัจจัยล่วงหน้า จะสามารถเตือนนักเรียนได้ก่อน



ต้องปรับชุดข้อมูลให้เป็น formal concept หรือไม่

เนื่องจากข้อมูลมีหลายฟีเจอร์ที่เป็นหมวดหมู่ เช่น กิจกรรม, อินเทอร์เน็ต,เกรด ซึ่งสามารถใช้ Association Rule Mining เช่น Apriori วิเคราะห์ความสัมพันธ์ได้ แต่ในการดำเนินงานครั้งนี้ ไม่ได้ใช้โมเดลนี้จริง เพราะมุ่งเน้นที่การทำนายความเสี่ยงสอบตกเป็นหลัก

การดำเนินการเตรียมพร้อมชุดข้อมูลให้สามารถใช้งานเทคนิคนั้นได้

Check missing value

พบ Missing Values ในบางฟีเจอร์ เช่น:
Attendance: 516
Assignments_Avg: 517
Parent_Education_Level: 1,794

การแก้ไข missing value

- ใช้ค่ามัธยฐานเติมข้อมูลตัวเลข
- ใช้ค่าฐานนิยมเติมข้อมูลหมวดหมู่
- ใช้ fillna() เติมค่าใน DataFrame แล้วตรวจสอบว่าไม่มี NaN คงเหลือหรือไม่


ลบ columns ที่ไม่ได้ใช้

Drop คอลัมน์ ที่ไม่ได้ใช้งาน เช่น Student_ID, First_Name, Last_Name , Email



การดำเนินการเตรียมพร้อมชุดข้อมูลให้สามารถใช้งาน เทคนิคนั้นได้

Check Correlation Matrix



ฟีเจอร์ที่มีความสัมพันธ์ ดังนี้

- Attendance มีความสัมพันธ์เชิงลบ กับ:
 - Assignments_Avg (-0.038)
 - Participation_Score (-0.03)
 - Sleep_Hours_per_Night (-0.036)

หมายถึง หากขาดเรียนมาก อาจสัมพันธ์กับการมีส่วนร่วมและผลการบ้านที่น้อยลง

- Participation_Score มีความสัมพันธ์ เชิงลบเล็กน้อย กับ:
 - Total_Score (-0.034)
 - Projects_Score (-0.026)
- Assignments_Avg มีความสัมพันธ์เชิงบวกเล็กน้อย กับ:
 - Study_Hours_per_Week (0.024)
 - Sleep_Hours_per_Night (0.019)

- Midterm_Score กับ Stress_Level มีความสัมพันธ์น้อย(0.0198)

หมายถึง นักเรียนที่คะแนนสอบกลางภาคสูง อาจมีความเครียดสูงขึ้นเล็กน้อย


▼ ความสัมพันธ์ต่ำมาก / ไม่ชัดเจน

โดยรวมแล้ว ฟีเจอร์ส่วนใหญ่ ไม่มีความสัมพันธ์ชัดเจนต่อกัน




Check Graph


กราฟการกระจาย ของเกรด



กราฟแสดงเพศ



กราฟแสดงการกระจายของ เกรดแต่ละสาขา




หลังจากทำ Data Cleaning

หลังจากที่ดูกราฟดูข้อมูลเบื้องต้น พบว่าเกรดของข้อมูลมันดูไม่ยุติธรรม ดังนั้นจึงเลือกที่จะสร้างเกรดใหม่ วัตจากคะแนนของเด็กๆที่ๆ ได้โดยตรงเพื่อความแม่นยำและยุติธรรม

Feature Engineering


- สร้าง Total_Score_New
 - Midterm_Score = 0.20
 - Final_Score = 0.30
 - Assignments_Avg = 0.15
 - Quizzes_Avg = 0.15
 - Projects_Score = 0.15
 - Participation_Score = 0.05
- สร้าง New_Grade แบบ A-F
 - A >= 80
 - B >= 70
 - C >= 60
 - D >= 50
 - F < 50
- สร้าง New_Failing_Grade
 - A,B,C = ผ่าน และ D ,F = ไม่ผ่าน




Check Correlation again

- ตัวแปรที่สัมพันธ์สูงกับการสอบตก: Total_Score_New, Final_Score, Midterm_Score, Projects_Score
 - Final Score --> Total_Score_New สูงที่สุด โดยมีค่า 0.72 ซึ่งหมายความว่า คะแนนสอบปลายภาคมีอิทธิพลต่อคะแนนรวมมากที่สุด
 - รองลงมาคือ Midterm Score ที่มีความสัมพันธ์ระดับปานกลาง (0.46) และ คะแนนจาก Projects, Assignments และ Quizzes ก็มีส่วนสัมพันธ์กับคะแนนรวมเช่นกัน ประมาณ 0.28-0.29
 - New_Failing_Grade พบว่าความสัมพันธ์เป็นลบอย่างชัดเจนกับหลายฟีเจอร์ เช่น Final Score (-0.41), Midterm Score (-0.31), และ Total Score ใหม่ (-0.56) แปลว่าหากคะแนนเหล่านี้ต่ำ นักเรียนจะมีโอกาสสอบตกสูงขึ้น


กราฟการกระจาย ของเกรด



การกระจายของ เกรดแต่ละเพศ



กราฟแสดงการกระจายของ เกรดแต่ละสาขา





Data Encoding

- ทำการแปลงข้อมูลให้เป็นตัวเลข
เช่น Gender, Extracurricular_Activities, Internet_Access_at_Home,
Parent_Education_Level, Family_Income_Level

Model Selection, Training and Evaluation

- แบ่งเกรด
1 = Fail => F, D เนื่องจาก F น้อยมากๆ เราเลยตัดสินใจเลือก D ด้วย
เพื่อที่จะไม่ทำให้ข้อมูลเกิด Overfitting
0 = Pass => A, B, C)
New_Failing_Grade
0 4,415 ผ่าน
1 585 ไม่ผ่าน

Model Selection, Training and Evaluation

เด็กสาขาไหนมีอัตราการสอบตกสูงที่สุด?

อัตราการสอบตกตามแผนก:

Mathematics	0.131213
CS	0.119683
Business	0.117296
Engineering	0.108237

สาขาที่มีอัตราการสอบตกมากที่สุด คือ Mathematics (13.12%) ✓




ปัจจัยใดส่งผลทำให้เด็กสอบตก?

Logistic Regression

- ✓ Accuracy: 0.527 (52.7%)
- ROC AUC Score: 0.489 (48.9%)

Feature	Coefficient	Impact
Family_Income_Level	0.041833	เพิ่มโอกาสสอบตก
Sleep_Hours_per_Night	0.026905	เพิ่มโอกาสสอบตก
Attendance	0.021827	เพิ่มโอกาสสอบตก
Parent_Education_Level	-0.009016	ลดโอกาสสอบตก
Stress_Level_(1-10)	-0.070316	ลดโอกาสสอบตก
Study_Hours_per_Week	-0.079842	ลดโอกาสสอบตก



✓ Coefficients ของ Stress และ Study Hours สอดคล้องกับความคาดหวัง แต่ Attendance และ Sleep Hours กลับดู “เพิ่มโอกาสตก” ซึ่งดูแปลก ดังนั้นเราจึงเช็ค K-Fold
จึงได้ค่า Accuracy 50.40% ค่อนข้าง คงที่ ในแต่ละ fold แต่ยัง ไม่สูงมาก แสดงให้เห็นว่า Logistic Regression อาจไม่เหมาะสมที่สุด กับข้อมูลชุดนี้
แต่ใช้ Logistic Regression เพื่อตีความความสัมพันธ์ของฟีเจอร์ ได้ดี แต่ไม่เหมาะใช้ทำนายผลลัพธ์

ปัจจัยใดส่งผลทำให้เด็กสอบตก?

Random Forest

✓ Accuracy: 0.822 (82.2%)

● ROC AUC Score: 0.522 (52.2%)

🎯 พฤติกรรมการเข้าเรียน และเวลาศึกษา คือปัจจัยสำคัญอันดับต้น ๆ 💡


โมเดลเข้าใจได้ง่าย และให้ข้อมูลปัจจัยได้ชัดเจน

ดังนั้นเราจึงเช็ค K-Fold

จึงได้ค่า Accuracy : 80.00% ถือว่าอยู่ในระดับที่ดีมาก

📊 ไม่มี Fold ไหนต่ำกว่า 0.77 โมเดลมีความ เสถียร (Stable)

✓ ช่วยยืนยันว่าโมเดล Random Forest ไม่ Overfitting กับชุดข้อมูล Training



ปัจจัยใดส่งผลทำให้เด็กสอบตก?

XGBoos

✓ Accuracy: 0.841 (84.1%)

● ROC AUC Score: 0.544 (54.4%)


🎯 จากกราฟ SHAP แสดงให้เห็นว่า

Study_Hours_per_Week, Attendance มีโอกาส สอบผ่านสูง
Sleep_Hours_per_Night, Stress_Level_(1-10) เพิ่มโอกาส สอบตก
Parent_Education_Level, Family_Income_Level ส่งผลน้อยมากๆ

ดังนั้นเราจึงเช็ค K-Fold

จึงได้ค่า Accuracy : 83.01% ถือว่าอยู่ในระดับที่ดีมากๆ

📈 ไม่มี Fold ไหนต่ำกว่า 0.80 แสดงว่าโมเดลมีความเสถียรมาก



สรุปเปรียบเทียบโมเดล เพื่อหาตัวที่เหมาะสมกับ Early Warning



Logistic Regression Model

Accuracy = 0.527 (52.7%)
ROC AUC Score = 0.489 (48.9%)
Feature Importance = เหมาะสม (ผ่าน Coefficients)
Cross-Validation Accuracy = 0.509 (50.9%)



Random Forest Model

Accuracy = 0.822 (82.2%)
ROC AUC Score = 0.522 (52.2%)
Feature Importance = เหมาะสม (ผ่าน Gini)
Cross-Validation Accuracy = 0.800 (80.0%)



XGBoost Model

Accuracy = 0.841 (84.1%)
ROC AUC Score = 0.544 (54.4%)
Feature Importance = เหมาะสม (ผ่าน SHAP)
Cross-Validation Accuracy = 0.830 (83.0%)

สรุป ควรใช้ XGBoost ในการพัฒนา Early Warning เพราะแม่นยำสุด และสามารถอธิบายผลลัพธ์ได้ด้วย

ผลลัพธ์จากแบบจำลองที่ครบถ้วนสำหรับเทคนิคนั้น

Early Warning Model คือระบบที่ใช้เทคนิค Machine Learning ในการประมวลผลข้อมูลพฤติกรรมและสภาพแวดล้อมของนักเรียน เพื่อทำนายความเสี่ยง ที่นักเรียนแต่ละคนอาจจะ สอบตก หรือมีผลการเรียนไม่ดีในอนาคต

🎯 จุดประสงค์ของโมเดล ค้นหานักเรียนที่ มีความเสี่ยงสูงต่อการสอบตก
แจ้งเตือนครู หรือนักเรียนล่วงหน้า

📊 นักเรียนทั้งหมด: 5,000

👉 เด็กตกจริง: 585

📢 เด็กที่โมเดลเตือน: 1,724

✅ แจ้งเตือนถูก (ตกจริง): 585

✅ Accuracy: 0.7722 (77.22%)

● ROC AUC Score: 0.9882 (98.82%)

ดูรายชื่อเด็กที่ตก (10 คนแรก)

คนที่ 4 , 5, 6, 12, 14, 18, 20, 23, 24, 33,.....

จากผลการทดลองและพัฒนาโมเดล XGBoost พบว่า สามารถระบุความเสี่ยงในการสอบตกได้อย่างแม่นยำ และสามารถต่อยอดเป็นระบบ **Early Warning** เพื่อช่วยเหลือนักเรียนได้ในอนาคต

ผลลัพธ์น่าพอใจหรือไม่? หรือยังมีประเด็นต่อเนื่องสำหรับทำ Data Science รอบต่อไปหรือไม่?

พบว่าโมเดลสามารถจับกลุ่มนักเรียนเสี่ยงได้จริง ผลลัพธ์โดยรวมถือว่าน่าพอใจในระดับหนึ่ง เนื่องจากสามารถทำนายความเสี่ยงสอบตกได้ และอธิบายปัจจัยสำคัญได้ชัดเจน
ประเด็นต่อเนื่องที่สามารถทำในรอบถัดไป เช่น ทำการปรับ Threshold ของโมเดลให้เหมาะสมกับสถานการณ์จริง

THANK YOU

