

การพัฒนาและประยุกต์ใช้ Data Science Workflow

กรณีศึกษา

จาก Workflow ต้นฉบับสู่การแบ่งกลุ่มนักศึกษา
และการปรับปรุงการทำงานจาก CLI1 สู่ CLI2



Workflow ต้นฉบับและการนำไปใช้

ภาพรวม

CLI1 และ CLI2 ใช้ Workflow กลาง 11 ขั้นเดียวกัน แต่ปรับรายละเอียดและการทำงานจริงต่างกัน

1

Workflow ต้นฉบับ 10 ขั้น

กำหนดลำดับงานกว้าง ตั้งแต่การตั้ง
โจทย์จนถึงรายงาน HTML
ยังไม่แยกบางขั้น และกำหนดบางวิธี
ตายตัวกับทุกประเภทงาน

2

Workflow กลาง 11 ขั้น

ใช้เป็นโครงร่างของ CLI1 และ CLI2
agy_workflow.md เพิ่มข้อกำหนดของ
Student Segmentation
CLI2 แก้โค้ด หลักฐาน และ Dashboard
หลังตรวจพบช่องว่างใน CLI1

สิ่งที่ขาดใน Workflow ต้นฉบับ

จุดเดิม

ผลกระทบต่อกระบวนการ

1

Data Cleaning รวมอยู่ใน EDA



ไม่ชัดเจนว่าต้องแก้คุณภาพข้อมูลก่อนเริ่มสำรวจ

2

ไม่มีขั้น Model Training แยก



การแบ่งข้อมูล การปรับค่า และการทำซ้ำไม่มีตำแหน่งชัดเจน

3

บังคับ Clustering 5+ และ Classification 5+



อาจฝึกโมเดลที่ไม่ตรงกับประเภทงาน

4

กำหนด Confusion Matrix สำหรับทุกงาน



เหมาะกับ Classification ที่มีคำตอบจริง แต่ไม่ใช่เกณฑ์หลักของ Clustering

5

Revise and adjust กว้าง และไม่มี Deployment หรือ Monitoring



ไม่มีกติกาว่าปรับเมื่อใด หยุดเมื่อใด นำไปใช้และติดตามอย่างไร

Workflow กลาง: ขั้นตอน 1-4

ขั้นตอน 1-4: กำหนดโจทย์และเตรียมข้อมูล

ขั้นตอนใหม่

ของเดิม

สิ่งที่เพิ่มหรือแก้

ผลดีที่เกิดขึ้น

1

Define problem and create problem statement

- Problem Definition
เพิ่มวัตถุประสงค์ ผลลัพธ์เป้าหมาย
ประเภทงาน และเกณฑ์ความสำเร็จ

ทุกขั้นตัดสินใจจากโจทย์และเกณฑ์เดียวกัน

2

Find data and load targeted data

- Data Gathering
เพิ่มแหล่งที่มา ขอบเขต และข้อจำกัดของข้อมูล

ตรวจสอบที่มาและทราบข้อจำกัดก่อนเริ่มวิเคราะห์

3

ส่วน Cleaning ที่เดิมรวมอยู่ใน EDA

- Data Cleaning
แยกการทำความสะอาดข้อมูล เป็นขั้นตอนเฉพาะ

จัดการค่าสูญหาย ข้อมูลซ้ำ ชนิดข้อมูล และ
ความไม่สอดคล้องก่อน EDA

4

ส่วน Analysis ที่เดิมรวมอยู่ใน EDA

- Exploratory Data Analysis
วิเคราะห์การกระจาย ค่าผิดปกติ รูปแบบ
ความสัมพันธ์ และตัวแปรสำคัญหลัง
Cleaning

เข้าใจข้อมูลจากชุดที่สะอาดขึ้นก่อนสร้างตัว
แปรหรือเลือก โมเดล

Workflow กลาง: ขั้นตอน 5-8

ขั้นตอน 5-8: พัฒนาและประเมินโมเดล

ขั้นตอนใหม่	ของเดิม	สิ่งที่เพิ่มหรือแก้	ผลดีที่เกิดขึ้น
5	สร้างและคัดเลือกตัวแปร (Feature Engineering)	- Feature engineering สร้าง แปลง และคัดเลือกตัวแปร รวมถึง เข้ารหัสหรือปรับมาตราส่วนเมื่อจำเป็น	ทำให้ข้อมูลเหมาะกับโมเดลและลดตัวแปรที่ไม่จำเป็น
6	ต้นฉบับแยก Literature Review และบังคับเลือก โมเดล 5+5	- Model selection รวมการทบทวนวรรณกรรมไว้กับการเลือกโมเดล และเลือก Candidate ตามโจทย์ ข้อมูล และงานที่ผ่านมา	เลือกเฉพาะโมเดลที่เหมาะสมกับประเภทงาน ไม่บังคับ Classification และ Clustering พร้อมกัน
7	ไม่มีขั้นฝึก โมเดล (Model Training) แยก	- Model Training แยกขั้นฝึกโมเดล แบ่งข้อมูลตามประเภทงาน แล้วฝึกและปรับค่าพารามิเตอร์	ทำให้การฝึก การปรับค่า และการทำซ้ำมี หลักฐานชัดเจน
8	ต้นฉบับกำหนด Model Evaluation และ Confusion Matrix แบบตายตัว	- Model Evaluation ใช้ Baseline ตัวชี้วัดที่เหมาะสมกับประเภทงาน และการวิเคราะห์ข้อผิดพลาด	Classification ใช้ Confusion Matrix ได้ ส่วน Clustering ใช้คุณภาพภายใน และความคงที่


วงจรปรับปรุงโมเดล (Model Optimization Cycle): ทำขั้นตอน 5-8 ซ้ำจนผ่านเกณฑ์ความสำเร็จ

Workflow กลาง: ขั้นตอน 9-11

ขั้นตอน 9-11: นำไปใช้ สื่อสาร และติดตาม

ขั้นตอนใหม่	ของเดิม	สิ่งที่เพิ่มหรือแก้	ผลดีที่เกิดขึ้น	
9	ไม่มีขั้นนำโมเดลไปใช้งาน	เพิ่มการนำโมเดลไปใช้งาน (Model Deployment)	นำโมเดลไปใช้ร่วมกับกระบวนการเตรียมข้อมูลและขั้นตอนสร้างผลลัพธ์	ลดความต่างระหว่างขั้นฝึกโมเดลกับการใช้ข้อมูลใหม่
10	Create visualization and HTML	ขยายเป็นการสื่อสารผลลัพธ์ (Communicate Results)	สื่อสารผล ข้อจำกัด และข้อเสนอแนะผ่านบทสรุป กราฟ และรายงาน HTML	ทำให้ผู้ฟังเข้าใจผลและตรวจสอบข้อจำกัดได้
11	ไม่มีขั้นติดตามผล	เพิ่มการติดตามและบำรุงรักษา (Monitor and Maintain)	ติดตามประสิทธิภาพโมเดลและการเปลี่ยนแปลงของข้อมูล พร้อมฝึกใหม่เมื่อจำเป็น	เมื่อพบการเปลี่ยนแปลงสำคัญ ให้กลับไปขั้นตอน 2 และทำ Workflow ใหม่

สรุป Workflow กลาง 11 ขั้นตอนแบบครบวงจร



การปรับ Workflow กลางให้เหมาะกับโครงการ

ข้อกำหนดเฉพาะโครงการ

- **หนึ่งแถวต่อนักศึกษา**
รวมข้อมูลรายวิชาตามรหัสนักศึกษาก่อนพิจารณาสุ่มข้อมูล
- **การสุ่มตัวอย่าง (Sampling) มีเหตุผลรองรับ**
ระบุวิธี จำนวน ตัวเลขสุ่มที่ใช้ การเป็นตัวแทน และข้อจำกัด
- **การแยกกักผลลัพธ์ (Outcome Quarantine)**
ไม่นำผลการเรียนมาใช้สร้างตัวแปร สุ่มข้อมูล หรือเลือกโมเดล
- **การล็อกโมเดล (Model Lock)**
บันทึก โมเดลและขั้นตอนเตรียมข้อมูล ก่อนเปิดดูผลการเรียน
- **ตรวจผลภายหลัง (Post-hoc) เท่านั้น**
ใช้ผลการเรียนเพื่ออธิบายความแตกต่างระหว่างกลุ่ม แต่ห้ามย้อนกลับไปปรับโมเดล

การปรับในหน้านี้เป็นกรนำ **Workflow** กลางมาระบุเงื่อนไขเฉพาะของ **Student Segmentation** เช่น หนึ่งแถวต่อนักศึกษา การแยกผลการเรียน และการล็อกโมเดล ไม่ใช่ความแตกต่างระหว่าง **CLI1** กับ **CLI2**

CLI1: การนำ Workflow ไปใช้ครั้งแรก

ข้อมูลที่อยู่ใน Prompt

- โครงการและแหล่งข้อมูล
- หนึ่งแถวต่อนักศึกษา
- เป้าหมายการแบ่งกลุ่ม
- ประเภทงาน Unsupervised Learning

สิ่งที่ได้ใน CLI1

มี Pipeline โค้ด โมเดล ผลการแบ่งกลุ่ม และ HTML Dashboard จึงเป็นการทำงานครบหลายขั้น แต่ยังมีบางจุดที่มีผลลัพธ์และลำดับการตัดสินใจไม่ตรงกับข้อกำหนด

สิ่งที่ตรวจพบ

- 1 ขั้นตอนการทำความสะอาดบางส่วนไม่ถูกนำไปใช้
- 2 เลือกโมเดลผู้ชนะจากคะแนนคุณภาพภายใน 4 ค่า ก่อนตรวจสอบความสามารถในการอธิบายกลุ่ม (Interpretability และความไวต่อวิธีเตรียมข้อมูล (Sensitivity))
- 3 การตรวจสอบข้อมูลก่อนใช้งานและติดตามผลไม่ครบตามที่ Workflow กล่าวไว้
- 4 Dashboard สรุปเฉพาะตัวแทนบางโมเดล ทำให้ที่มาของ 4 กลุ่มอธิบายยาก
- 5 รายละเอียดบางส่วนของรายงานยังใช้งานไม่ครบ

ปัญหาไม่ได้เกิดจากโครง Workflow กลาง แต่เกิดจาก agy_workflow.md รุ่นแรกยังระบุกฎบางส่วนไม่ชัด และโค้ดปฏิบัติไม่ตรงกับข้อกำหนดทุกจุด

CLI2: ปรับการนำ Workflow ไปใช้ให้ตรงกับข้อกำหนด

หลักการ: ใช้ Workflow กลาง 11 ขั้นเดิม แต่ปรับ agy_workflow.md โค้ด หลักฐาน และ Dashboard ให้สอดคล้องกัน

ข้อมูลและการทำความสะอาด

แก้การจัดการวันที่ผิดพลาด และตรวจสอบว่าไม่มีนักศึกษาสูญหาย หลังรวมข้อมูล

การเลือกโมเดล

เปรียบเทียบ 6 กลุ่มวิธี 29 การตั้งค่า พร้อมตรวจสอบความคงที่ และความสามารถในการอธิบายก่อนเลือกโมเดล

การนำโมเดลไปใช้

เพิ่มการตรวจชนิดข้อมูล ค่าว่าง ช่วงค่า ข้อมูลซ้ำ และป้องกันผลการเรียน รั่วไหลเข้าสู่โมเดล

การติดตามผล

ตรวจสอบเปลี่ยนแปลงของข้อมูล ค่าผิดปกติ ความไม่แน่นอน และความคงที่ของกลุ่ม

Dashboard

แสดงผลจากไฟล์จริง เพิ่มตารางโมเดล โปรไฟล์กลุ่ม เมนูแบบย่อ และเครื่องมือจำลองสถานการณ์

การทำซ้ำและตรวจสอบ

บันทึกค่าตั้งต้น การตั้งค่า บันทึกการทำงาน และตรวจไฟล์ผลลัพธ์ให้ครบ

การแก้วันที่ การตรวจข้อมูลก่อนใช้งานข้างต้น เป็นการแก้โค้ดให้ทำงานตรงกับ agy_workflow ที่ระบุไว้

CLI2: จุดที่แก้ไขใน agy_workflow.md

Step 7 — เพิ่มการบันทึกการใช้หน่วยความจำ ระยะเวลาประมวลผล และค่าเริ่มต้นการสุ่ม (Seed)

Step 8 — กำหนดลำดับการตัดสินใจ:
คัดเลือกโมเดลเบื้องต้น → ตรวจสอบก่อนยืนยัน → ยืนยันโมเดล → ตรวจสอบผลลัพธ์ภายหลัง

Step 8 — ผลลัพธ์ — แยกหลักฐานการตรวจสอบ:
ความสามารถในการอธิบายผล การทดสอบเมื่อตัดตัวแปรออก และความไวต่อการเปลี่ยนแปลงของการเตรียมข้อมูล

Step 9 — เพิ่มขอบเขตการรับข้อมูลใหม่และกฎตรวจสอบข้อมูลก่อนนำโมเดลไปใช้งาน

กฎการดำเนินงาน — กำหนดให้ไฟล์การตั้งค่า (Config) เป็นแหล่งอ้างอิงกลางของระบบ

CLI1 และ CLI2: Workflow เดียวกัน ต่างกันที่การนำไปใช้

เปรียบเทียบการทำงาน

หัวข้อ	CLI1	CLI2
โครง Workflow	ใช้ Workflow กลาง 11 ชั้น	ใช้ Workflow กลาง 11 ชั้นเหมือนเดิม
agy_workflow.md	กำหนดงานเฉพาะโครงการแล้ว แต่บางเงื่อนไขยังรวมไว้กว้าง	ระบุลำดับการเลือกและล็อกโมเดล หลักฐานที่ต้องตรวจ ขอบเขตข้อมูลใหม่ และไฟล์ตั้งค่ากลางให้ชัดเจน
โค้ดและหลักฐาน	บางส่วนไม่ตรงกับกฎการทำความสะอาดข้อมูล การเลือกโมเดล การนำไปใช้ และการติดตามผล	แก้โค้ดและเพิ่มบันทึกการตรวจสอบ การทดสอบ และรายการไฟล์ผลลัพธ์ เพื่อให้ตรวจย้อนหลังได้
Dashboard	มีรายงานแล้ว แต่ตาราง เมนู การแสดงโมเดล แต่รายละเอียดไม่ครบ เนื้อหาหาย	แสดงข้อมูลจากไฟล์ผลลัพธ์จริง ตารางครบ เมนูย่อได้ และเครื่องมือจำลองสถานการณ์ใช้งานได้
สถานะผลลัพธ์	มีโมเดลและผลแบ่งกลุ่ม แต่ยังมีช่องว่างในการตรวจรับ	ตรวจไฟล์ผลลัพธ์ให้ครบ และการนำโมเดลไปใช้ผ่านการทดสอบ

สิ่งที่ดีขึ้นหลังพัฒนา

ก่อนปรับ

ขั้นตอนกว้าง

ใช้โมเดลและตัวชี้วัดแบบเดียวกับทุก โจทย์

เสี่ยงเห็นผลลัพธ์ก่อนเลือก โมเดล

มีผลลัพธ์แต่ตรวจย้อนกลับยาก

จบที่รายงาน HTML

หลังปรับ

ลำดับงาน กฎตัดสินใจ และผลลัพธ์ของแต่ละขั้นชัดเจน

เลือกวิธีตาม Classification หรือ Clustering

แยกผลลัพธ์ และล็อก โมเดลก่อนตรวจผลภายหลัง

เชื่อมข้อมูล โค้ด ตาราง กราฟ โมเดล Log และ Test เข้าด้วยกัน

เพิ่ม Deployment, Monitoring และ Feedback Loop

Workflow ที่เหมาะสมช่วยลดความผิดพลาด ทำให้กระบวนการตรวจสอบได้ และนำผลไปใช้อย่างระมัดระวัง

ส่วนที่ 2

กรณีศึกษาการแบ่งกลุ่มนักศึกษา

การประยุกต์ Workflow 11 ขึ้นกับข้อมูล MOOC
ผลลัพธ์อยู่ช่วงท้ายเพื่อแยกจากเรื่องการพัฒนา Workflow

ข้อมูลจริง 416,921 ระเบียบน นักศึกษาไม่ซ้ำ 335,650 คน
งานแบบไม่มีคำตอบกำกับ (Unsupervised Learning)

กรณีศึกษา: ภาพรวมโครงการ

บทนำ

เป้าหมายคือค้นหากลุ่มพฤติกรรมของนักศึกษา
เพื่อใช้ประกอบการวางแผนสนับสนุน

416,921

records ในไฟล์จริง

22 columns

335,650

นักศึกษาไม่ซ้ำ

หนึ่งแถวต่อนักศึกษา

29

model configurations

6 families ที่ต่างกันจริง

4

กลุ่มพฤติกรรม

K-Means

การกำหนดปัญหา (Problem Definition)

ขั้นตอน 1

โจทย์

ค้นหากลุ่มนักศึกษาที่มีรูปแบบการมีส่วนร่วมแตกต่างกัน โดยไม่ใช้ผลลัพธ์การเรียนรู้กำหนดกลุ่ม

ประเภทงาน

การแบ่งกลุ่มแบบไม่มีคำตอบกำกับ
(Unsupervised Clustering)


หน่วยวิเคราะห์

หนึ่งแถวต่อนักศึกษา

เกณฑ์ความสำเร็จ

- ตัวชี้วัดภายในแสดงว่ากลุ่มแยกจากกันและมีความกระชับเหมาะสม
- ผลแบ่งกลุ่มคงที่เมื่อสุ่มข้อมูลซ้ำและเปลี่ยนค่าเริ่มต้น
- แต่ละกลุ่มตีความจากพฤติกรรมจริงได้
- ขนาดกลุ่มและเวลาประมวลผลเหมาะสมกับการใช้งาน
- ผลการเรียนรู้ใช้ตรวจสอบภายหลังเท่านั้น

Kaggle MOOC Dataset



หนึ่งคนอาจลงทะเบียนหลายวิชา จึงรวมแถวของคนเดียวกันให้เหลือหนึ่งแถว

จำนวนข้อมูลไม่ได้หายเพราะการลบ แต่เกิดจากการรวมหลายทะเบียนของนักศึกษาคนเดียวกันตาม userid_DI ให้เหลือหนึ่งแถวต่อนักศึกษา โดยตรวจสอบแล้วไม่สูญเสียนักศึกษาระหว่างการรวมข้อมูล

การแยกกักผลลัพธ์ (Outcome Quarantine)

ขั้นตอน 2

ตัวแปรที่ทราบผลภายหลัง

certified

grade

explored

incomplete_flag



พัฒนาโมเดล

สร้างตัวแปร
เลือกโมเดลและจำนวนกลุ่ม
ฝึกและปรับค่า
ประเมินด้วยตัวชี้วัดภายใน
(internal metrics)



เลือกโมเดล

บันทึก model
และ
preprocessing
checksum

หลังเลือกแล้วจึงเปิดผลการเรียนเพื่อตรวจสอบภายหลัง (Post-hoc Validation)
โดยห้ามย้อนกลับไปปรับ โมเดลจากผลที่เห็น

การทำความสะอาดและรวมข้อมูลระดับนักศึกษา

ขั้นตอน 3

ค่าสูญหาย
(Missing Values)

รักษา missing เมื่อความหมายไม่แน่นอน ไม่แทนเป็นศูนย์โดยไม่มีหลักฐาน

วันที่ผิดพลาด

เก็บช่วงเวลาที่คำนวณไม่ได้เป็น missing และบันทึกจำนวนที่ได้รับผลกระทบ

ชนิดข้อมูล
(Data Types)

แปลงตัวเลขและวันที่ก่อน aggregate พร้อมตรวจค่าผิดปกติรูปแบบ

การรวมข้อมูลระดับนักศึกษา รวม course records ตาม userid_DI ด้วยกฎเฉพาะแต่ละตัวแปร

*วันที่เริ่มต้นที่อยู่หลังวันที่ทำกิจกรรมล่าสุดถือว่าไม่สมเหตุสมผล จึงเก็บช่วงเวลาดังกล่าวเป็นค่าสูญหาย แทนการบังคับให้เป็นศูนย์ เพื่อให้ข้อมูลผิดถูกตีความว่าเป็นการเรียนระยะสั้น

ผลตรวจการทำความสะอาด

0

นักศึกษาสูญหาย



1,171

คนมีวันที่กลับด้าน

ความไม่แน่นอนของวันที่
ถูกเก็บไว้ใน audit

การวิเคราะห์ข้อมูลเชิงสำรวจ (EDA)

ขั้นตอน 4



EDA ใช้ประชากรทั้งหมดและไม่เปิดผลการเรียน

ตรวจการกระจาย ความเบี่ยง ค่าผิดปกติ สหสัมพันธ์ และความเกี่ยวข้องของตัวแปรก่อนสร้างโมเดล

ข้อค้นพบสำคัญ

ตัวแปรพฤติกรรมกระจายเบ้ขวาและมีค่าศูนย์จำนวนมาก


ข้อมูลวิดีโอขาด 56.82% จึงแปลงข้อมูลด้วย log1p ปรับมาตราส่วน และทดสอบความไวของตัวแปรวิดีโอ

ตัวแปรพฤติกรรมหลัก 8 ตัว

- | | |
|------------------------|---|
| ● จำนวนวิชาที่ลง | ● จำนวน chapters |
| ● อัตราการดูเนื้อหา | ● โพสต์ในกระดานสนทนา (forum posts) |
| ● จำนวน events | ● ช่วงเวลาการมีส่วนร่วม |
| ● จำนวนวันที่มีกิจกรรม | ● กิจกรรมต่อวันที่ใช้งาน (events /active day) |

วิธีเตรียม

- log1p ลด skew
- median imputation เฉพาะที่มีเหตุผล
- scaling ป้องกันตัวแปรค่ามากครอบงำ



ข้อมูลวิดีโอแยกไว้ทดสอบความไว (Sensitivity Test)

Core + video ให้ Silhouette 0.3268 ต่ำกว่า core 0.3737
จึงไม่ใช้ video ในโมเดลสุดท้าย

การทบทวนวรรณกรรมและเลือกโมเดล

ขั้นตอน 6

งานวิจัยสนับสนุนการแบ่งกลุ่มเพื่อค้นหารูปแบบผู้เรียน โดยไม่กำหนดคำตอบจากผลการเรียนล่วงหน้า

อิงจุดศูนย์กลาง(Centroid)

K-Means
baseline ที่ scale ได้

อิงความน่าจะเป็น(Probabilistic)

Gaussian Mixture
รูปทรงวงรีและความน่าจะเป็น

CF-tree

BIRCH
เหมาะกับข้อมูลขนาดใหญ่

ลำดับชั้นแบบแบ่งออก(Divisive)

Bisecting K-Means
ลำดับชั้นแบบแบ่งออก

ลำดับชั้นแบบรวมเข้า(Agglomerative)

Ward linkage
ลำดับชั้นแบบรวมเข้า

อิงความหนาแน่น(Density)

DBSCAN
ทดสอบกลุ่มตามความหนาแน่น

ทดลอง 29 การตั้งค่า จาก 6 กลุ่มวิธี และคัดจำนวนกลุ่ม 4, 5, 6 และ 12 จากผลทดลองเบื้องต้น

หลักฐานอ้างอิง: Tseng et al. (2016); Peach et al. (2019); Zhang et al. (1996, BIRCH); Ester et al. (1996, DBSCAN)

*Workflow กลางไม่ได้กำหนดจำนวนโมเดลตายตัว โครงการนี้เลือก 6 กลุ่มวิธีที่มีกลไกแตกต่างกัน หลังพิจารณางานวิจัย ลักษณะข้อมูล ขนาดข้อมูล และความสามารถในการนำไปใช้กับข้อมูลใหม่ ไม่ได้เลือก Classification เพราะโจทย์ไม่มีคำตอบกลุ่มจริงกำกับ

การฝึกโมเดล (Model Training) และการแบ่งข้อมูล

ขั้นตอน 7



เหตุผลที่ใช้ข้อมูลตัวอย่างเฉพาะการเปรียบเทียบโมเดล

- 1 บาง algorithm ต้องคำนวณระยะทางเป็นคู่ จึงกำหนด pairwise-memory budget 256 MB
- 2 ใช้ deterministic seed = 612731450 ซึ่ง derive จาก checksum ของข้อมูล
- 3 ตรวจสอบ representativeness โดยไม่ใช้ outcome: maximum standardized mean difference = 0.0171
- 4 โมเดลที่ชนะถูก refit กับนักศึกษาทั้งหมดก่อน deployment

*ใช้ข้อมูลตัวอย่างเพื่อให้การทดลองหลายโมเดลอยู่ภายใต้ทรัพยากรเดียวกันและเปรียบเทียบได้อย่างเป็นธรรม แต่หลังเลือกโมเดลแล้ว ได้ฝึกโมเดลสุดท้ายกับนักศึกษาทั้งหมด 335,650 คน

การเลือก โมเดล (Model Selection)

จำนวนกลุ่มไม่ได้กำหนดไว้ล่วงหน้า แต่ได้จากการทดลองและเปรียบเทียบกับกฎเดียวกัน

1

สำรวจจำนวนกลุ่ม

ทดลอง k ตั้งแต่ 2-13



2

คัดจำนวนที่น่าสนใจ

เลือก 4, 5, 6 และ 12 กลุ่ม



3

ทดลองโมเดล

ทดลอง 29 การตั้งค่า
24 คารองรับข้อมูลใหม่และมี
metric ครบ



4

เปรียบเทียบ

จัดอันดับ 24 ค่า
ด้วยตัวชี้วัด 4 ด้าน
อีก 5 ค่าใช้เป็น geometry
benchmark



5

เลือกคำตอบ

K-Means 4 กลุ่ม
ได้อันดับรวมดีที่สุด

*อีก 5 การตั้งค่าใช้เป็น Geometry Benchmark เนื่องจากไม่รองรับการกำหนดกลุ่มให้ข้อมูลใหม่หรือมีหลักฐานไม่ครบ จึงไม่รวมในการจัดอันดับผู้ชนะ

วิธีอ่านเกณฑ์ประเมินการแบ่งกลุ่ม

เกณฑ์ประเมิน

เกณฑ์	คำอธิบายภาษาง่าย	ทิศทาง
Silhouette	สมาชิกอยู่ใกล้กลุ่มตัวเองมากกว่ากลุ่มอื่นเพียงใด	สูงดีกว่า
Davies–Bouldin	กลุ่มกระชับและแยกจากกันเพียงใด	ต่ำดีกว่า
Calinski–Harabasz	เปรียบเทียบความแตกต่างระหว่างกลุ่มกับความกระจายภายในกลุ่ม	สูงดีกว่า
ความคงที่เมื่อสุ่มซ้ำ (Resample ARI)	เมื่อสุ่มข้อมูลใหม่ สมาชิกยังอยู่กลุ่มเดิมมากเพียงใด	สูงดีกว่า
Mean internal rank	อันดับรวมจากคะแนนทั้ง 4	ต่ำดีกว่า

ผลเปรียบเทียบโมเดลจาก 6 กลุ่มวิธี

ผลลัพธ์

กลุ่มวิธี / โมเดล	จำนวนกลุ่ม	Silhouette ↑	Davies–Bouldin ↓	Calinski–Harabasz ↑	Resample ARI↑	Mean internal rank↓
Agglomerative Ward	4	0.333	1.011	2,815	—	—
BIRCH	4	0.339	1.043	787	0.579	16.75
Bisecting K-Means	5	0.322	1.127	2,834	0.912	12.25
DBSCAN	15	0.231	0.898	1,762	—	—
Gaussian Mixture	6	0.377	1.015	2,804	0.918	7.75
K-Means	4	0.374	0.986	3,194	0.980	3


ตารางแสดงตัวแทนที่ดีที่สุดของแต่ละกลุ่มวิธี การจัดอันดับผู้ชนะใช้ 24 การตั้งค่าที่นำไปใช้งานได้จากทั้งหมด 29 การตั้งค่า ส่วน DBSCAN ไม่กำหนด k แต่พบ 15 กลุ่มและ Noise 29.9%

คะแนนคำนวณจากตัวอย่างประเมิน 5,792 คน เพื่อควบคุมเวลาและเปรียบเทียบอย่างเท่าเทียม
หลังเลือกและล็อกโมเดลแล้ว จึงฝึก K-Means จำนวน 4 กลุ่มกับนักศึกษาทั้งหมด 335,650 คน

ขนาดและลักษณะของนักศึกษา 4 กลุ่ม

ผลลัพธ์

สัดส่วนนักศึกษาในแต่ละกลุ่ม



แท่งยาวแสดงสัดส่วนเทียบกับช่วง 0-50%

Cluster 0 - 96,906 คน (28.87%)

core behaviors ต่ำกว่าค่าเฉลี่ยทั้งหมด และ view rate ต่ำที่สุด

Cluster 1 - 78,687 คน (23.44%)

active days และ activity volume สูง แต่ forum posts ต่ำ

Cluster 2 - 154,822 คน (46.13%)

view rate สูงกว่าเฉลี่ย แต่ active days ต่ำกว่าเฉลี่ย


Cluster 3 - 5,235 คน (1.56%)

ทุก core behavior สูงกว่าเฉลี่ย โดย forum posts สูงที่สุด

*Cluster 0 — กลุ่มการมีส่วนร่วมค่อนข้างต่ำ Cluster 1 — กลุ่มทำกิจกรรมต่อเนื่อง Cluster 2 — กลุ่มรับชมเนื้อหาเป็นหลัก Cluster 3 — กลุ่มมีส่วนร่วมสูง

การแบ่งกลุ่มและวิเคราะห์ความคลุมเครือ

ผลลัพธ์



จุดที่ต้องระวัง

13.89%

สมาชิกกลุ่ม 1 มีค่า Negative Silhouette ในตัวอย่างประเมิน

ความหมาย


การวิเคราะห์ข้อผิดพลาดของงานแบ่งกลุ่ม
ตรวจความทับซ้อนและความไม่แน่นอน
นักศึกษาบางส่วนอยู่ใกล้ขอบเขตกลุ่มอื่น
จึงไม่ควรถือผลการจัดกลุ่มเป็นข้อเท็จจริง
เด็ดขาด

*Negative Silhouette หมายถึงนักศึกษาบางคนอยู่ใกล้ขอบเขตระหว่างกลุ่ม จึงอาจมีลักษณะคล้ายอีกกลุ่มหนึ่ง ผลการแบ่งกลุ่มควรใช้เพื่อดูแนวโน้มภาพรวม ไม่ควรใช้เป็นคำตัดสินรายบุคคลแบบเด็ดขาด

Pre-lock Review (ตรวจหลักฐานเหล่านี้ก่อนยืนยันโมเดลสุดท้าย)

ขั้นตอน 8

หลักฐานเพิ่มเติม



ตรวจให้ครบก่อนล็อกโมเดล โดยไม่เปิดผลการเรียน

ความสำคัญจากการสลับค่าตัวแปร (Permutation Importance)

อัตราการดูเนื้อหา (view_rate) สำคัญที่สุด โดยค่า ARI ลดลงเฉลี่ย 0.3636

การตัดกลุ่มตัวแปรออกเพื่อทดสอบ (Feature-group Ablation)

เมื่อตัดกลุ่มตัวแปรปริมาณกิจกรรม ค่า ARI เหลือ 0.5561 แสดงว่าโครงสร้างกลุ่มเปลี่ยนชัด

การตรวจความเป็นธรรม (Fairness Diagnostics)

ไม่ใช่ข้อมูลประชากรศาสตร์สร้างกลุ่มความสัมพันธ์สูงสุด คือประเทศ (country) โดย Cramér's $V = 0.0812$

ผลตรวจสอบภายหลังล็อกโมเดล (Post-hoc Validation)

ผลการเรียนรู้ตรวจสอบความเกี่ยวข้องของกลุ่มภายหลังเท่านั้น และไม่มีผลต่อ feature, sampling, tuning หรือการเลือกโมเดล

ผลลัพธ์	วิธีวัด	ค่า Effect size	การใช้ผล
Any certified	Cramér's V	0.3575	บรรยายความแตกต่างระหว่างกลุ่ม
Any explored	Cramér's V	0.4884	บรรยายความแตกต่างระหว่างกลุ่ม
Certification rate	Epsilon-squared	0.1277	ใช้ตรวจภายหลัง ไม่ย้อนกลับไปปรับ โมเดล
Mean grade	Epsilon-squared	0.3790	ใช้ตรวจภายหลัง ไม่ตีความเป็นเหตุและผล
Incomplete rate	Epsilon-squared	0.0334	รายงานพร้อมข้อจำกัด

Cluster 1

explored 32.91% · certified 16.10%

Cluster 3

explored 33.43% · certified 21.15%

การนำไปใช้งาน รายงานผล และติดตาม

ขั้นตอน 9-11



การนำโมเดลไปใช้งาน (Deployment)

รวมขั้นตอนเตรียมข้อมูลและโมเดลไว้ในกระบวนการเดียวกัน ตรวจสอบค่าสูญหาย ชนิดข้อมูล ช่วงค่า นักศึกษาซ้ำ และป้องกันข้อมูลผลลัพธ์รั่วไหลเข้าสู่โมเดล

การสื่อสารผลลัพธ์ (Communication)

สร้างรายงาน HTML จากไฟล์ผลลัพธ์จริงของระบบ แสดงขั้นตอนการทำงาน การสำรวจข้อมูล การเปรียบเทียบโมเดล ลักษณะของแต่ละกลุ่ม และข้อจำกัดของผลการวิเคราะห์

การติดตามและบำรุงรักษา (Monitoring)

ค่าฐานจากข้อมูลฝึก:

- ความไม่แน่นอนของการกำหนดกลุ่ม = 0.505
- สัดส่วนข้อมูลผิดปกติ = 1.00%
- ความคงที่เมื่อฝึกโมเดลใหม่ = 0.961 ARI
- สถานะ not_evaluated เพราะยังไม่มีข้อมูลนักศึกษารุ่นใหม่สำหรับเปรียบเทียบ

หากพบการเปลี่ยนแปลงโครงสร้างข้อมูล (Schema Change) รูปแบบข้อมูลเปลี่ยนไป (Data Drift) หรือคุณภาพการแบ่งกลุ่มลดลง ให้ย้อนกลับไปขั้นตอนที่ 2 เพื่อรวบรวมและตรวจสอบข้อมูลใหม่

สรุปการพัฒนา Workflow และผลที่ได้

ข้อจำกัดของการวิเคราะห์

- ข้อมูล MOOC เป็นข้อมูลในอดีตอาจไม่สามารถแทนผู้เรียนปัจจุบัน
- การรวมหนึ่งแถวต่อคนทำให้ลำดับเวลาและบริบทรายวิชาหายไป
- กลุ่มมีความเสถียรสูงแต่ยังทับซ้อนบางส่วน
- Video missing 56.82% จึงไม่ใช้ใน core model
- ไม่รับประกันประโยชน์หรือความเป็นธรรม

ขั้นตอนต่อไป

- ตรวจสอบกับนักศึกษารุ่นใหม่
- ให้ผู้เชี่ยวชาญด้านการศึกษช่วยตรวจสอบความหมายของแต่ละกลุ่ม
- ประเมินผลของมาตรการช่วยเหลือก่อนใช้งานในวงกว้าง
- ติดตาม Cluster 3 ซึ่งมีเพียง 1.56% อย่างระมัดระวัง
- ฝึกโมเดลใหม่เมื่อข้อมูลหรือหลักสูตรเปลี่ยนไป

สิ่งที่เพิ่มจากต้นฉบับ

- Data Cleaning
- Model Training
- Model Optimization Cycle
- Feedback Loop
- Deployment, Communication, Monitoring
- Outcome quarantine
- Model lock
- Outputs, Checksums, Logs, Tests

ผลลัพธ์ที่ได้

- K-Means แบ่งนักศึกษาเป็น 4 กลุ่ม
- ฝึกโมเดลกับนักศึกษา 335,650 คน
- ความคงที่ของกลุ่ม (ARI) = 0.9803
- กระบวนการนำไปใช้ผ่านการทดสอบ 10/10
- ไฟล์หลักฐานครบ 75/75 รายการ

ข้อสรุป

Workflow ที่เหมาะสมช่วยลดความผิดพลาด ทำให้กระบวนการตรวจสอบได้ และนำผลไปใช้อย่างระมัดระวัง

ขอบคุณค่ะ

